Examen d'Intelligence Artificielle

Corrigé détaillé

Professeur Joseph Azar, Maître de conférences UMLP
Cours ELC2 — Apprentissage
Formation L3 Informatique, parcours Produits et services multimédia

Pour chaque question, vous trouverez le **sujet**, puis le **corrigé** dans un encadré vert avec le détail du barème. Essayez d'abord de répondre sans regarder.

Les documents, téléphones et calculatrices sont interdits. La durée de l'examen est de 1 h 30.

Barème : partie 1 : 6 points · partie 2 : 6 points · partie 3 : 5 points · partie 4 : 3 points. Total : 20 points.

Partie 1 : Questions de cours fondamentales — 6 points

Cette partie vise à vérifier votre compréhension des concepts de base vus en cours. Elle est conçue pour être accessible à tous.

Q1. Questions à choix multiples — 1,5 point (0,5 par question)

Pour chaque question, entourez la seule bonne réponse.

1. Lequel de ces problèmes est un problème de **classification** ?

   a) Prédire le prix d'une maison.

   b) Prédire si un client va résilier son abonnement (oui/non).

   c) Regrouper des clients en segments de marché.

   Corrigé. Réponse : b) Prédire si un client va résilier son abonnement (oui/non).
   C'est une classification binaire (deux catégories : oui ou non). La réponse a) est une régression (on prédit un prix), la réponse c) est du clustering (non supervisé).

2. Qu'est-ce que l'apprentissage **non supervisé** ?

   a) Apprendre à partir de données étiquetées par un expert.

   b) Apprendre en recevant des récompenses ou des punitions.

   c) Apprendre à trouver des structures dans des données non étiquetées.

   Corrigé. Réponse : c) Apprendre à trouver des structures dans des données non étiquetées.
   L'apprentissage non supervisé n'a pas d'étiquettes (de réponses connues). La réponse a) décrit l'apprentissage supervisé, la réponse b) l'apprentissage par renforcement.

3. À quoi sert la **normalisation** des données (Min-Max Scaling) ?

   a) À supprimer les valeurs manquantes.

   b) À mettre toutes les variables sur une échelle commune (par exemple de 0 à 1).

   c) À transformer des variables textuelles en nombres.

> **Corrigé. Réponse : b)** À mettre toutes les variables sur une échelle commune (par exemple de 0 à 1).
> La normalisation Min-Max ramène les valeurs dans un intervalle fixe, souvent $[0, 1]$. Cela évite qu'une variable aux grandes valeurs domine les autres.

Q2. Vrai ou faux

2,5 points (0,5 par question)

Indiquez si chaque affirmation est vraie ou fausse.

1. La régression linéaire est utilisée pour prédire une catégorie. Vrai / Faux

> **Corrigé. Faux.** La régression linéaire prédit une **valeur continue** (un nombre), pas une catégorie.

2. L'algorithme KNN (K-Nearest Neighbors) est sensible à l'échelle des données. Vrai / Faux

> **Corrigé. Vrai.** KNN repose sur la distance euclidienne. Si une variable a une échelle beaucoup plus grande (un salaire en euros contre un âge en années), elle domine le calcul de la distance. Il faut donc mettre les variables à la même échelle.

3. Une matrice de confusion permet d'évaluer la performance d'un modèle de clustering. Vrai / Faux

> **Corrigé. Faux.** La matrice de confusion sert à évaluer un problème de **classification** (supervisé), où l'on connaît la vraie réponse. Elle ne sert pas pour le clustering (non supervisé).

4. Le « sur-ajustement » (overfitting) signifie que le modèle est trop simple et ne capture pas la tendance des données. Vrai / Faux

> **Corrigé. Faux.** Le sur-ajustement signifie que le modèle est **trop complexe** : il apprend par cœur les données d'entraînement, bruit compris. Un modèle trop simple provoque, lui, un *sous-ajustement*.

5. Le « One-Hot Encoding » est utilisé pour transformer des variables catégorielles nominales en format numérique. Vrai / Faux

> **Corrigé. Vrai.** Le One-Hot Encoding transforme une variable catégorielle nominale (par exemple couleur = rouge, bleu, vert) en plusieurs colonnes binaires (rouge = 1 ou 0, bleu = 1 ou 0, vert = 1 ou 0).

Q3. Questions courtes

2 points (1 par question)

Répondez en une ou deux phrases claires.

1. Quelle est la principale différence entre la **régression** et la **classification** ?

> **Corrigé. Réponse attendue.** La régression prédit une **valeur continue** (par exemple un prix ou une température), tandis que la classification prédit une **catégorie** ou **classe** (par exemple chat/chien, spam/normal).

2. Expliquez brièvement l'idée principale de l'algorithme **K-Means**.

> **Corrigé. Réponse attendue.** K-Means regroupe les données en K clusters : il rattache chaque point au centre (centroïde) le plus proche, puis recalcule les centres, et recommence jusqu'à convergence. L'objectif est de minimiser la distance entre les points et leur centre.

Partie 2 : Cas pratiques simples

6 points

Dans cette partie, vous appliquerez vos connaissances à des cas simples. Les calculs sont guidés.

Cas pratique 1 : classification avec KNN

2 points

Vous êtes consultant pour un vétérinaire qui souhaite prédire si un animal est un chat ou un chien en se basant sur son poids et la longueur de ses griffes. Vous disposez des données suivantes :

Animal	Poids (kg)	Longueur des griffes (cm)	Espèce
A	3	1,0	Chat
B	12	0,8	Chien
C	4	1,2	Chat
D	9	0,9	Chien

Un nouvel animal, **E**, arrive à la clinique. Il pèse **5 kg** et ses griffes mesurent **1,1 cm**. Vous devez prédire son espèce avec l'algorithme **KNN avec** $K = 3$.

1. Calculez la distance euclidienne entre le nouvel animal **E** et chacun des 4 autres animaux (la formule est fournie en annexe).

> **Corrigé.** (0,5 point)
> $d(E, A) = \sqrt{(5-3)^2 + (1{,}1-1{,}0)^2} = \sqrt{4 + 0{,}01} = \sqrt{4{,}01} \approx \mathbf{2{,}00}$
> $d(E, B) = \sqrt{(5-12)^2 + (1{,}1-0{,}8)^2} = \sqrt{49 + 0{,}09} = \sqrt{49{,}09} \approx \mathbf{7{,}01}$
> $d(E, C) = \sqrt{(5-4)^2 + (1{,}1-1{,}2)^2} = \sqrt{1 + 0{,}01} = \sqrt{1{,}01} \approx \mathbf{1{,}00}$
> $d(E, D) = \sqrt{(5-9)^2 + (1{,}1-0{,}9)^2} = \sqrt{16 + 0{,}04} = \sqrt{16{,}04} \approx \mathbf{4{,}00}$

2. Quels sont les 3 plus proches voisins de **E** ?

> **Corrigé.** (0,5 point)
> Du plus proche au plus éloigné : **C** (distance $\approx 1{,}00$, chat), **A** (distance $\approx 2{,}00$, chat), **D** (distance $\approx 4{,}00$, chien).

3. Quelle est l'espèce majoritaire parmi ces 3 voisins ?

> **Corrigé.** (0,5 point)
> **Chat** : 2 chats contre 1 chien.

4. Conclusion : selon KNN avec $K = 3$, l'animal **E** est-il un chat ou un chien ?

> **Corrigé.** (0,5 point)
> L'animal **E** est un **chat**.

Cas pratique 2 : régression linéaire simple

2 points

Une startup de vélos électriques veut prédire l'autonomie (en km) d'un vélo en fonction du poids du cycliste (en kg). Elle a trouvé le modèle de régression linéaire suivant :

$$\text{Autonomie (km)} = -0{,}5 \times \text{Poids (kg)} + 100$$

1. Quelle serait l'autonomie prédite pour un cycliste de **70 kg** ?

> **Corrigé.** (0,5 point)
> $-0{,}5 \times 70 + 100 = -35 + 100 = \mathbf{65\ km}$.

2. Quelle serait l'autonomie prédite pour un cycliste de **100 kg** ?

> **Corrigé.** (0,5 point)
> $-0{,}5 \times 100 + 100 = -50 + 100 = \mathbf{50\ km}$.

3. Interprétez le coefficient $-0{,}5$. Que signifie-t-il concrètement ?

> **Corrigé.** (1 point)
> Pour chaque kilogramme supplémentaire du cycliste, l'autonomie du vélo diminue de 0,5 km. Plus le cycliste est lourd, moins le vélo a d'autonomie.

Cas pratique 3 : interprétation d'une matrice de confusion

2 points

Vous avez créé un modèle pour détecter les e-mails de spam. Après l'avoir testé sur 100 e-mails, vous obtenez la matrice de confusion suivante :

	Prédit : Normal	**Prédit : Spam**
Réel : Normal	85 (VN)	2 (FP)
Réel : Spam	5 (FN)	8 (VP)

1. Combien d'e-mails ont été correctement classifiés au total ?

> **Corrigé.** (0,5 point)
> $VP + VN = 8 + 85 = \mathbf{93}$ e-mails.

2. Calculez l'**accuracy** (exactitude) du modèle.

> **Corrigé.** (0,5 point)
> $\text{Accuracy} = \dfrac{VP + VN}{\text{Total}} = \dfrac{8 + 85}{100} = \dfrac{93}{100} = \mathbf{0{,}93}$, soit 93 %.

3. Calculez la **precision** (précision) pour la classe « Spam ».

> **Corrigé.** (0,5 point)
> $\text{Precision} = \dfrac{VP}{VP + FP} = \dfrac{8}{8 + 2} = \dfrac{8}{10} = \mathbf{0{,}8}$, soit 80 %.

4. Interprétez en une phrase ce que signifie la précision que vous venez de calculer.

> **Corrigé.** (0,5 point)
> Une précision de 80 % signifie que, lorsque le modèle prédit qu'un e-mail est un spam, il a raison 80 % du temps. Autrement dit, 20 % des e-mails classés comme spam sont en réalité des e-mails normaux (faux positifs).

Partie 3 : Analyse et application

5 points

Vous êtes consultant en IA. Un client vous présente un problème. Vous devez analyser la situation et proposer une solution argumentée.

Étude de cas : la plateforme de streaming vidéo « StreamFlix »

« StreamFlix » est une nouvelle plateforme de streaming. Pour améliorer l'expérience des utilisateurs, elle souhaite développer deux fonctionnalités fondées sur l'IA.

Fonctionnalité 1 : personnalisation des vignettes. StreamFlix veut prédire sur quel type de vignette (image d'aperçu) un utilisateur est le plus susceptible de cliquer. Pour chaque film, il existe 3 vignettes différentes : une avec un personnage (A), une avec un paysage (B) et une avec du texte (C). La plateforme veut prédire, pour chaque utilisateur, quelle vignette (A, B ou C) fonctionnera le mieux.

Fonctionnalité 2 : estimation du temps de visionnage. StreamFlix veut prédire combien de minutes un utilisateur va regarder d'un film donné. Cette prédiction sera utilisée pour optimiser la mise en cache des vidéos sur ses serveurs.

Vos tâches de consultant :

1. Pour la **fonctionnalité 1**, de quel type de problème de machine learning s'agit-il (régression, classification binaire, classification multi-classe, clustering…) ? Justifiez votre choix en une phrase. (1 point)

> **Corrigé.** (1 point)
> **Classification multi-classe.** Il y a 3 catégories possibles (vignette A, B ou C), et l'on veut prédire laquelle sera la plus efficace pour chaque utilisateur.

2. Pour la **fonctionnalité 2**, de quel type de problème de machine learning s'agit-il ? Justifiez votre choix en une phrase. (1 point)

> **Corrigé.** (1 point)
> **Régression.** On veut prédire une valeur continue (un nombre de minutes de visionnage), pas une catégorie.

3. Pour la **fonctionnalité 1**, votre équipe a testé deux algorithmes et obtenu les résultats suivants. Quel algorithme recommanderiez-vous, et pourquoi ? (1,5 point)

   — **Algorithme 1 (KNN)** : accuracy = 75 %, temps de prédiction par utilisateur = 2 secondes.

   — **Algorithme 2 (arbre de décision)** : accuracy = 72 %, temps de prédiction par utilisateur = 0,01 seconde.

   Indice : pensez au contexte d'une plateforme de streaming avec des millions d'utilisateurs.

> **Corrigé.** (1,5 point : 0,5 pour le choix, 1 pour la justification)
> **Algorithme 2 (arbre de décision).** Son accuracy est un peu plus faible (72 % contre 75 %), mais son temps de prédiction est **200 fois plus court** (0,01 s contre 2 s). Pour une plateforme avec des millions d'utilisateurs qui chargent des pages en temps réel, la vitesse est essentielle : 2 secondes par prédiction seraient inacceptables en production. Trois points d'accuracy en moins sont un prix acceptable pour répondre vite à tous les utilisateurs. La justification doit citer le contexte temps réel et le passage à l'échelle.

4. Pour la **fonctionnalité 2**, le premier modèle de régression a un R^2 de 0,2. Que signifie ce score ? Le modèle est-il performant ? Que suggéreriez-vous pour l'améliorer ? (1,5 point)

> **Corrigé.** (1,5 point)
> **Signification** (0,5 point) : le modèle n'explique que 20 % de la variation du temps de visionnage ; les 80 % restants ne sont pas capturés. C'est un score très faible.
> **Performance** (0,25 point) : non, le modèle n'est pas performant, ses prédictions sont mauvaises.
> **Pistes d'amélioration** (0,75 point) :
> — ajouter des variables (historique de visionnage, genre préféré, heure de la journée, type d'appareil…) ;
> — essayer un modèle plus souple (régression polynomiale, arbres de décision) ;
> — collecter davantage de données d'entraînement ;
> — vérifier la qualité des données (valeurs manquantes, valeurs aberrantes).

Partie 4 : Questions avancées — 3 points

Cette partie est conçue pour les étudiants qui visent une note supérieure à 15/20. Elle demande une réflexion

plus approfondie.

Question 1 : le dilemme du clustering

1,5 point

Vous êtes consultant pour un site e-commerce qui souhaite segmenter ses clients. Vous décidez d'utiliser l'algorithme **K-Means**. Votre collègue vous dit : « C'est simple, il suffit de choisir un K élevé, par exemple $K = 100$, pour avoir des groupes très précis ! »

Êtes-vous d'accord avec lui ? Expliquez les risques liés à un choix de K trop élevé ou trop bas. Décrivez brièvement une méthode vue en cours pour choisir une valeur de K plus objectivement.

Corrigé. (1,5 point : 0,5 pour les risques, 1 pour la méthode)

Non, je ne suis pas d'accord. Un K trop élevé ou trop bas pose des problèmes.

- K **trop bas** : les clusters sont trop larges et hétérogènes. Avec $K = 2$, on pourrait mettre tous les clients « actifs » dans un groupe et tous les « inactifs » dans l'autre, sans distinction plus fine.
- K **trop élevé** : c'est de la sur-segmentation. Avec $K = 100$, chaque cluster contient très peu de clients (peut-être 1 ou 2), ce qui rend l'analyse et l'action marketing impossibles. Chaque petit groupe risque en plus de capturer du bruit (sur-ajustement).

Méthode pour choisir K : la méthode du coude (*elbow method*). On teste plusieurs valeurs de K (par exemple de 1 à 10) ; pour chacune, on calcule l'**inertie** (la somme des distances au carré entre les points et leur centre) ; on trace l'inertie en fonction de K. On choisit le K où la courbe forme un « coude » : au-delà, ajouter des clusters n'améliore plus nettement l'inertie.

Question 2 : améliorer un modèle de classification

1,5 point

Vous avez développé un modèle pour diagnostiquer une maladie rare. Le modèle a une **accuracy de 98 %**, mais un **recall de seulement 15 %**.

1. Expliquez pourquoi une accuracy élevée peut être trompeuse dans ce contexte de maladie rare.

   Corrigé. (0,5 point)

   Si la maladie est rare (par exemple 2 % de la population), un modèle « naïf » qui répond toujours « pas malade » aurait une accuracy de 98 % : il a raison 98 % du temps. Pourtant, il est inutile, car il ne détecte **aucun** malade. L'accuracy ne reflète pas la performance sur la classe minoritaire (les malades).

2. Pourquoi un faible recall est-il très problématique pour un diagnostic médical ?

   Corrigé. (0,5 point)

   Le recall mesure la part des vrais malades que le modèle détecte. Un recall de 15 % signifie que 85 % des malades passent inaperçus (faux négatifs). En médecine, c'est grave : ces personnes ne seront pas soignées et leur état peut s'aggraver.

3. Proposez une piste concrète pour améliorer le recall de votre modèle, même si cela doit faire baisser un peu l'accuracy.

> **Corrigé.** (0,5 point)
> **Abaisser le seuil de décision.** Avec une régression logistique, au lieu de classer « malade » si $P > 0{,}5$, on peut classer « malade » dès que $P > 0{,}2$. Le modèle prédit alors « malade » plus souvent : plus de vrais positifs (meilleur recall), mais aussi plus de faux positifs (precision plus basse, accuracy qui peut baisser). C'est un compromis acceptable en médecine : mieux vaut un faux positif, qu'on vérifiera avec d'autres examens, qu'un malade non détecté.
> **Autres pistes acceptables** : rééquilibrer les classes (sur-échantillonner la classe minoritaire, sous-échantillonner la classe majoritaire), pondérer les classes dans l'algorithme, ou suivre le F1-score pour équilibrer precision et recall.

Annexe : formules utiles

— **Distance euclidienne** entre deux points $P_1(x_1, y_1)$ et $P_2(x_2, y_2)$:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

— **Accuracy (exactitude)** : $\dfrac{VP + VN}{\text{Total}}$

— **Precision (précision)** : $\dfrac{VP}{VP + FP}$

— **Recall (rappel)** : $\dfrac{VP}{VP + FN}$