Examen d'Intelligence Artificielle

Sujet de l'an dernier, proposé pour réviser

Professeur Joseph Azar, Maître de conférences UMLP
Cours ELC2 — Apprentissage
Formation L3 Informatique, parcours Produits et services multimédia

> *Les documents, téléphones et calculatrices sont interdits. La durée de l'examen est de 1 h 30.*
> **Barème :** partie 1 : 6 points · partie 2 : 6 points · partie 3 : 5 points · partie 4 : 3 points. Total : 20 points.

Partie 1 : Questions de cours fondamentales — 6 points

Cette partie vise à vérifier votre compréhension des concepts de base vus en cours. Elle est conçue pour être accessible à tous.

Q1. Questions à choix multiples — 1,5 point (0,5 par question)

Pour chaque question, entourez la seule bonne réponse.

1. Lequel de ces problèmes est un problème de **classification** ?
   a) Prédire le prix d'une maison.
   b) Prédire si un client va résilier son abonnement (oui/non).
   c) Regrouper des clients en segments de marché.
2. Qu'est-ce que l'apprentissage **non supervisé** ?
   a) Apprendre à partir de données étiquetées par un expert.
   b) Apprendre en recevant des récompenses ou des punitions.
   c) Apprendre à trouver des structures dans des données non étiquetées.
3. À quoi sert la **normalisation** des données (Min-Max Scaling) ?
   a) À supprimer les valeurs manquantes.
   b) À mettre toutes les variables sur une échelle commune (par exemple de 0 à 1).
   c) À transformer des variables textuelles en nombres.

Q2. Vrai ou faux — 2,5 points (0,5 par question)

Indiquez si chaque affirmation est vraie ou fausse.

1. La régression linéaire est utilisée pour prédire une catégorie. Vrai / Faux
2. L'algorithme KNN (K-Nearest Neighbors) est sensible à l'échelle des données. Vrai / Faux
3. Une matrice de confusion permet d'évaluer la performance d'un modèle de clustering. Vrai / Faux
4. Le « sur-ajustement » (overfitting) signifie que le modèle est trop simple et ne capture pas la tendance des données. Vrai / Faux

5. Le « One-Hot Encoding » est utilisé pour transformer des variables catégorielles nominales en format numérique. Vrai / Faux

Q3. Questions courtes

2 points (1 par question)

Répondez en une ou deux phrases claires.

1. Quelle est la principale différence entre la **régression** et la **classification** ?
2. Expliquez brièvement l'idée principale de l'algorithme **K-Means**.

Partie 2 : Cas pratiques simples

6 points

Dans cette partie, vous appliquerez vos connaissances à des cas simples. Les calculs sont guidés.

Cas pratique 1 : classification avec KNN

2 points

Vous êtes consultant pour un vétérinaire qui souhaite prédire si un animal est un chat ou un chien en se basant sur son poids et la longueur de ses griffes. Vous disposez des données suivantes :

Animal	Poids (kg)	Longueur des griffes (cm)	Espèce
A	3	1,0	Chat
B	12	0,8	Chien
C	4	1,2	Chat
D	9	0,9	Chien

Un nouvel animal, **E**, arrive à la clinique. Il pèse **5 kg** et ses griffes mesurent **1,1 cm**. Vous devez prédire son espèce avec l'algorithme **KNN avec** $K = 3$.

1. Calculez la distance euclidienne entre le nouvel animal **E** et chacun des 4 autres animaux (la formule est fournie en annexe).
2. Quels sont les 3 plus proches voisins de **E** ?
3. Quelle est l'espèce majoritaire parmi ces 3 voisins ?
4. Conclusion : selon KNN avec $K = 3$, l'animal **E** est-il un chat ou un chien ?

Cas pratique 2 : régression linéaire simple

2 points

Une startup de vélos électriques veut prédire l'autonomie (en km) d'un vélo en fonction du poids du cycliste (en kg). Elle a trouvé le modèle de régression linéaire suivant :

$$\text{Autonomie (km)} = -0{,}5 \times \text{Poids (kg)} + 100$$

1. Quelle serait l'autonomie prédite pour un cycliste de **70 kg** ?
2. Quelle serait l'autonomie prédite pour un cycliste de **100 kg** ?
3. Interprétez le coefficient $-0{,}5$. Que signifie-t-il concrètement ?

Cas pratique 3 : interprétation d'une matrice de confusion

2 points

Vous avez créé un modèle pour détecter les e-mails de spam. Après l'avoir testé sur 100 e-mails, vous obtenez la matrice de confusion suivante :

	Prédit : Normal	**Prédit : Spam**
Réel : Normal	85 (VN)	2 (FP)
Réel : Spam	5 (FN)	8 (VP)

1. Combien d'e-mails ont été correctement classifiés au total ?
2. Calculez l'**accuracy** (exactitude) du modèle.
3. Calculez la **precision** (précision) pour la classe « Spam ».
4. Interprétez en une phrase ce que signifie la précision que vous venez de calculer.

Partie 3 : Analyse et application

5 points

Vous êtes consultant en IA. Un client vous présente un problème. Vous devez analyser la situation et proposer une solution argumentée.

Étude de cas : la plateforme de streaming vidéo « StreamFlix »

« StreamFlix » est une nouvelle plateforme de streaming. Pour améliorer l'expérience des utilisateurs, elle souhaite développer deux fonctionnalités fondées sur l'IA.

Fonctionnalité 1 : personnalisation des vignettes. StreamFlix veut prédire sur quel type de vignette (image d'aperçu) un utilisateur est le plus susceptible de cliquer. Pour chaque film, il existe 3 vignettes différentes : une avec un personnage (A), une avec un paysage (B) et une avec du texte (C). La plateforme veut prédire, pour chaque utilisateur, quelle vignette (A, B ou C) fonctionnera le mieux.

Fonctionnalité 2 : estimation du temps de visionnage. StreamFlix veut prédire combien de minutes un utilisateur va regarder d'un film donné. Cette prédiction sera utilisée pour optimiser la mise en cache des vidéos sur ses serveurs.

Vos tâches de consultant :

1. Pour la **fonctionnalité 1**, de quel type de problème de machine learning s'agit-il (régression, classification binaire, classification multi-classe, clustering…) ? Justifiez votre choix en une phrase. (1 point)
2. Pour la **fonctionnalité 2**, de quel type de problème de machine learning s'agit-il ? Justifiez votre choix en une phrase. (1 point)
3. Pour la **fonctionnalité 1**, votre équipe a testé deux algorithmes et obtenu les résultats suivants. Quel algorithme recommanderiez-vous, et pourquoi ? (1,5 point)
   - **Algorithme 1 (KNN)** : accuracy = 75 %, temps de prédiction par utilisateur = 2 secondes.
   - **Algorithme 2 (arbre de décision)** : accuracy = 72 %, temps de prédiction par utilisateur = 0,01 seconde.

   Indice : pensez au contexte d'une plateforme de streaming avec des millions d'utilisateurs.

4. Pour la **fonctionnalité 2**, le premier modèle de régression a un R^2 de 0,2. Que signifie ce score ? Le modèle est-il performant ? Que suggéreriez-vous pour l'améliorer ? (1,5 point)

Partie 4 : Questions avancées

3 points

Cette partie est conçue pour les étudiants qui visent une note supérieure à 15/20. Elle demande une réflexion plus approfondie.

Question 1 : le dilemme du clustering

1,5 point

Vous êtes consultant pour un site e-commerce qui souhaite segmenter ses clients. Vous décidez d'utiliser l'algorithme **K-Means**. Votre collègue vous dit : « C'est simple, il suffit de choisir un K élevé, par exemple $K = 100$, pour avoir des groupes très précis ! »

Êtes-vous d'accord avec lui ? Expliquez les risques liés à un choix de K trop élevé ou trop bas. Décrivez brièvement une méthode vue en cours pour choisir une valeur de K plus objectivement.

Question 2 : améliorer un modèle de classification

1,5 point

Vous avez développé un modèle pour diagnostiquer une maladie rare. Le modèle a une **accuracy de 98 %**, mais un **recall de seulement 15 %**.

1. Expliquez pourquoi une accuracy élevée peut être trompeuse dans ce contexte de maladie rare.
2. Pourquoi un faible recall est-il très problématique pour un diagnostic médical ?
3. Proposez une piste concrète pour améliorer le recall de votre modèle, même si cela doit faire baisser un peu l'accuracy.

Annexe : formules utiles

— **Distance euclidienne** entre deux points $P_1(x_1, y_1)$ et $P_2(x_2, y_2)$:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

— **Accuracy (exactitude)** : $\dfrac{VP + VN}{\text{Total}}$

— **Precision (précision)** : $\dfrac{VP}{VP + FP}$

— **Recall (rappel)** : $\dfrac{VP}{VP + FN}$