

La demande

Un mail, un fichier Excel, et un prestataire qui dit non

ELC2 — Introduction au machine learning — Séance 1

Où vous êtes. Vous venez d'arriver chez Comtoise Auto Occasion, un vendeur de voitures d'occasion avec trois agences : Montbéliard, Belfort et Besançon. Ce matin, la directrice vous transfère ce message.

Boîte de réception

De : Nathalie Girard, directrice

À : vous

Objet : Notre fichier de ventes — le prestataire n'en veut pas

Pièce jointe : ventes-3-agences.xlsx

Bonjour,

Nous voulons un outil qui estime tout seul le prix de reprise d'une voiture : le client donne la marque, le modèle, l'année, le kilométrage et le carburant, et l'outil propose un prix. Aujourd'hui, chaque vendeur estime à l'œil, et deux vendeurs ne donnent jamais le même prix pour la même voiture.

Un prestataire doit construire cet outil par *machine learning*, à partir de nos ventes de 2025. Chaque agence tient son propre tableau Excel ; je les ai rassemblés en un seul fichier, celui qui est joint, et je le lui ai envoyé. Voici sa réponse :

« Votre fichier ne peut pas être utilisé en l'état. Un modèle apprend ce qu'on lui montre : si les données sont fausses, ses prix seront faux, et il les donnera avec assurance. Nettoyez-le d'abord, ou comptez trois jours de préparation facturés. »

— Julien Faivre, DataComtoise

Je ne comprends pas : toutes nos ventes sont dedans. Avant jeudi, j'ai besoin de savoir :

1. Quels sont les problèmes de ce fichier ? Pour chacun, un exemple, et combien de lignes sont touchées.
2. Que faut-il faire pour chacun : corriger, supprimer, compléter ?
3. Au bout du compte, combien de ventes pourra-t-il vraiment utiliser ?

Nathalie

Ce que contient ce document.

Page 2 : les 20 premières lignes du fichier, qui en compte 146, telles qu'Excel les affiche. Nous les parcourons ensemble pour repérer tout ce qui semble faux, bizarre ou manquant. Il y en a au moins quinze, dont un invisible.

Page 3 : le tableau qui répond à Nathalie, que nous remplissons ensemble pour les 146 lignes.

L'extrait — les 20 premières lignes de ventes-3-agences.xlsx

Présenté comme Excel l'affiche. La colonne grise à gauche est le numéro de ligne. **etat** : l'état constaté par l'atelier. **remise** : la remise accordée, en % du prix affiché.

	ref	agence	marque	modele	annee	kilometrage	carburant	etat	remise	prix	notes
1	V-0001	Montbéliard	Peugeot	308	2021	96570	Diesel	Bon	5,0	13400	
2	V-0002	Montbeliard	Dacia	Duster	2022	30159	Diesel	Très bon	7,0	12400	
3	V-0003	Belfort	Citroën	C4	2013	145 395 km	Essence	Correct	6,4	3400	
4	V-0004	Montbéliard	Peugeot	308	2013	245277	Gazole	Mauvais	5,6	2500	
5	V-0005	Besançon	Citroën	C3	2018	201541	Diesel	Correct	6,9		
6	V-0006	Belfort	Dacia	Sandero	2024	15401	Essence	Tres bon	6,0	11000	
7	V-0007	Montbéliard	Renault	Clio	2015	169600	essence	Correct	4,0	3100	
8	V-0008	Besançon	Volkswagen	Golf	2018	80874	Hybride	Bon	5,3	9 000 €	
9	V-0009	Besançon	Toyota	Yaris	2031	24800	Hybride	Très bon	6,2	11200	
10	V-0010	Belfort	Citroën	C4	2021		Diesel	Bon	8,0	12800	
11	V-0011	Montbéliard	Dacia	Sandero	2022	43454	Essence	Bon	7,4	7500	
12	V-0012	Montbéliard	Dacia	Sandero	2024	7531	Essence	Très bon	5,8	1	
13	V-0004	Montbéliard	Peugeot	308	2013	245277	Gazole	Mauvais	5,6	2500	
14	V-0013	Montbéliard	Renault	Mégane	2015	1250000	Diesel	Correct	6,6	5100	
15	V-0014	Besançon	Toyota	Yaris	2023	12936		Très bon	4,5	16500	
16	V-0015	Besançon	Citroen	C3	2017	67042	Essence	Bon	5,9	4900	
17	V-0016	Montbéliard	Dacia	Sandero	2019	66355	Essence	Correct	48,0	4800	
18	V-0017	Besançon	Peugeot	208	2019	61240	Essence	Bon	7,1	77000	
19	V-0018	Montbéliard	Volkswagen	Golf	2020	97306	DIESEL	Bon	6,3	11300	
20	V-0019	Besancon	Renault	Captur	2020	34316	Hybride	Bon	5,2	12200	

Quatre questions à se poser devant un fichier : une même information est-elle écrite de plusieurs façons ? Y a-t-il des valeurs qu'aucune voiture ne peut avoir ? Pourquoi certains nombres sont-ils calés à gauche, et les autres à droite ? Une même vente peut-elle apparaître deux fois ?

Le tableau pour Nathalie — à remplir ensemble

Questions 1 et 2 : les problèmes, et ce qu'on en fait.

Problème	Colonne(s)	Exemple (ligne)	Combien	Que faire ?

Question 3 : combien de ventes utilisables ?

Étape	Nombre de lignes
Dans le fichier reçu	
Après avoir retiré les doublons	
Vraiment utilisables pour apprendre un prix	

On ne corrige pas un fichier à la main. Sur 146 lignes, on en oublierait. On repère les problèmes sur un extrait, on les classe, puis on laisse l'ordinateur compter et corriger, sur tout le fichier.

Ce que devient ce fichier ensuite

Vous ne le retaperez pas. Vous installerez Jupyter sur votre ordinateur et vous ouvrirez un premier notebook qui refait, en Python et en quelques lignes, chaque étape vue au tableau, sur les 146 lignes. Chaque correction y est écrite noir sur blanc : on peut la relire, la vérifier, et la refaire le jour où Nathalie enverra les ventes de 2026.