

Le machine learning, et ses données

ELC2 · Introduction au machine learning · Séance 1

Joseph Azar · Maître de Conférences, UMLP · Chercheur FEMTO-ST
joseph.azar@umlp.fr

À la fin de cette séance, vous saurez

1. dire ce qu'est le machine learning, et trouver ce qui ne va pas dans un fichier ;
2. lire une colonne de nombres comme une **distribution**, et savoir ce que sa forme implique ;
3. mesurer si deux colonnes disent la même chose, la **corrélation**, et pourquoi n'en garder qu'une ;
4. repérer les **valeurs aberrantes**, et choisir entre z-score et quartiles ;
5. transformer du texte en nombres : **one-hot** ou **ordinal**, et pourquoi ;
6. mettre les colonnes à la même échelle : **normaliser** ou **standardiser**, et pourquoi ;
7. ouvrir Jupyter sur votre ordinateur, et y refaire tout cela.

PARTIE 1

L'IA et le machine learning, l'essentiel

IA, ou pas IA ?

La chose	Réponse
La calculatrice qui fait $1\,234 \times 56$	Non. Une règle écrite par un humain.
Le filtre anti-spam de votre messagerie	Oui. Il a appris sur des millions de mails.
Une formule <code>=SOMME()</code> dans Excel	Non. Une règle.
Le téléphone qui reconnaît votre visage	Oui. Il a appris à partir de photos.
Le thermostat qui chauffe dès qu'il fait moins de 19 °C	Non. Une règle fixe.
Le GPS qui annonce un bouchon à 17 h avant qu'il existe	Oui. Il a appris des trajets passés.

Ce que les « oui » ont en commun


Personne n'a écrit la règle.

La machine l'a trouvée **dans des exemples**.

Personne n'a écrit « un spam contient tel mot ». On a montré des millions de mails, chacun marqué spam ou pas spam, et la machine a trouvé elle-même ce qui les distingue.

L'**intelligence artificielle** (IA), c'est un programme qui fait une tâche qu'on croyait réservée à l'intelligence humaine : reconnaître, traduire, prévoir, écrire.

Des poupées russes



IA : tout programme « intelligent », même à règles.

Machine learning : apprend à partir d'exemples. Le filtre anti-spam.

Deep learning : du machine learning avec de très gros « réseaux de neurones ». La reconnaissance de visages.

IA générative : produit du texte, des images. ChatGPT, Le Chat, Gemini.

Deux façons de faire travailler un ordinateur

La programmation classique : un humain écrit la règle.



Le machine learning : la machine trouve la règle.



Le **machine learning** (apprentissage automatique) : faire trouver une règle à un ordinateur, à partir d'exemples dont on connaît déjà la réponse.

Un exemple : le prix d'une voiture d'occasion

Écrire la règle ? « Le prix neuf, moins 15 % par an. »

Voiture	Âge	Kilomètres	La règle dit	Le marché dit
Peugeot 308 essence	4 ans	40 000	~14 600 €	plus
Peugeot 308 diesel	4 ans	210 000	~14 600 €	beaucoup moins

On ajoute une règle pour les kilomètres, le carburant, l'état, le modèle...
On n'en finit jamais.

Montrer des exemples : on donne toutes les ventes passées, avec leur prix. La machine trouve elle-même comment le prix dépend de l'âge, des kilomètres, de l'état.

Le vocabulaire, sur un tableau

marque	modele	annee	kilometrage	carburant	etat	prix
Peugeot	308	2021	96 570	Diesel	Bon	13 400
Dacia	Duster	2022	30 159	Diesel	Très bon	12 400
Dacia	Sandero	2024	15 401	Essence	Très bon	11 000
Dacia	Sandero	2019	66 355	Essence	Correct	4 800

Une **ligne** = un **exemple**. Ici, une vente.

Une **colonne** qui décrit l'exemple = une **caractéristique**. En anglais : feature.

La colonne qu'on veut apprendre à deviner = la **cible**. En anglais : target ou label. Ici, le prix.

La règle trouvée par la machine = le **modèle**. Apprendre se dit aussi **entraîner**.

Trois grandes questions

La question	La réponse est...	Exemples
Classer	une catégorie	ce mail est-il un spam ? cette machine va-t-elle tomber en panne ?
Prédire un nombre	un nombre	combien vaut cette voiture ? combien de vélos loués demain ?
Regrouper	des groupes, qu'on ne connaissait pas	quels clients se ressemblent ?

Les noms savants : **classification**, **régression**, **clustering**. Chacune aura sa séance, avec son entreprise et son fichier.

Un projet de machine learning, en six étapes

1

Poser la question

2

Rassembler les données

3

Préparer les données

4

Apprendre

5

Évaluer

6

Utiliser

L'étape 3 est la moins spectaculaire, et celle où les équipes passent **la plus grande partie de leur temps**.

Aujourd'hui : toute l'étape 3. Nettoyer, lire les distributions, traiter les valeurs aberrantes, encoder, mettre à l'échelle.

Des données fausses, des réponses fausses

En anglais : *garbage in, garbage out*.

Un modèle entraîné sur des données fausses **fonctionne très bien**. Il donne des prix. Des prix faux, avec assurance. Il reproduit aussi leurs déséquilibres : on parle de **biais**.

Rien ne s'affiche en rouge. Personne n'est prévenu.

Le règlement européen sur l'IA exige d'ailleurs, pour les usages à risque, des données d'entraînement « aussi exemptes d'erreurs et complètes que possible ».

UN CAS

Comtoise Auto Occasion

La situation

- Un vendeur de voitures d'occasion, trois agences : **Montbéliard, Belfort, Besançon.**
- La directrice, Nathalie, veut un **outil qui estime le prix de reprise tout seul.**
- Chaque agence tient son propre Excel. Nathalie les a rassemblés et envoyés au prestataire.

Le prestataire refuse le fichier : « Un modèle apprend ce qu'on lui montre : si les données sont fausses, ses prix seront faux. Nettoyez-le d'abord. »

Nathalie ne comprend pas : **toutes les ventes sont dedans.**

Entreprise, personnes et ventes fictives. Les villes sont réelles et servent d'étiquettes.

À vous, par deux

Page 2 : les **20 premières lignes** du fichier, qui en compte 146.

1. **Entourez** tout ce qui vous semble faux, bizarre ou manquant.
2. Notez le problème dans la colonne de droite.
3. **Ne corrigez rien.** On cherche, on ne répare pas encore.

Il y en a **au moins quinze**. L'un d'eux est invisible.

Vous avez Excel ou LibreOffice ? `ventes-3-agences.xlsx` est sur la page GitHub du cours.
Essayez le filtre de la colonne `agence`.

Cinq familles de problèmes

Famille	Dans l'extrait (numéro de ligne)
Doublons	ligne 13 = ligne 4, à l'identique
Une même chose écrite de plusieurs façons	Montbeliard (2), Gazole (4), Tres bon (6), essence (7), Citroen (16), DIESEL (19), Besancon (20)
Des nombres écrits comme du texte	145 395 km (3), 9 000 € (8) : calés à gauche
Des valeurs aberrantes	année 2031 (9), 1 € (12), 1 250 000 km (14), remise 48 % (17), 77 000 € pour une 208 de 2019 (18)
Des cases vides	prix (5), kilométrage (10), carburant (15)

Le problème que personne ne voit

Ligne 11 : Montbéliard 
avec un **espace à la fin**.

Sur papier : invisible. Pour
l'ordinateur : **une autre agence**.

Dans le filtre d'Excel, « Montbéliard » et
« Belfort » apparaissent deux fois. Rien
ne dit pourquoi.

Filtre de la colonne **agence**

☒ (Sélectionner tout)

☒ Belfort

☒ Belfort

☒ Besancon

☒ Besançon

☒ Montbeliard

☒ Montbéliard

☒ Montbéliard

Reconstitution du filtre, sur tout le fichier.

Préparer les données, en huit étapes

1

Regarder avant de
toucher

2

Les doublons

3

Le texte écrit de
plusieurs façons

4

Les nombres écrits en
texte

5

Les valeurs aberrantes

6

Les cases vides

7

Encoder le texte

8

Mettre à l'échelle

Les étapes 1 à 4 réparent. Entre 4 et 5, deux outils pour tout le reste : **la distribution** (une colonne) et **la corrélation** (deux colonnes). Les étapes en bleu sont le cœur de la séance.

Deux règles avant de toucher à quoi que ce soit : **on garde l'original** (on travaille sur une copie), et **on note chaque décision**.

Regarder, puis les doublons

146 lignes, **10** colonnes, et un onglet **dictionnaire** qui dit ce que veut dire chaque colonne. Demandez-le toujours.

	ref	modele	annee	kilometrage	prix
4	V-0004	308	2013	245277	2500
13	V-0004	308	2013	245277	2500

La même vente, saisie deux fois. Le modèle lui donnerait deux fois plus de poids.

146 → 140

Deux Sandero vendues au même prix ne sont pas un doublon. Un doublon, c'est **la même vente** : même référence, toutes les colonnes identiques.

Une même chose, neuf écritures

agence, telle qu'écrite	lignes
Montbéliard · Besançon · Belfort	44 · 42 · 40
Montbeliard · MONTBELIARD · Montbéliard	4 · 1 · 1
Besancon · besançon	3 · 2
Belfort	3

marque l'espace invisible. 14 lignes mal écrites.

La méthode, en trois gestes :

1. enlever les espaces aux deux bouts ;
2. tout écrire en minuscules ;
3. une **table de correspondance** :
montbeliard → Montbéliard, besancon → Besançon...

9 écritures → **3 agences**. Même méthode pour la marque (*Citroen, PEUGEOT*) et l'état (*Tres bon*).

Le carburant, et ce qu'aucune règle ne devine

carburant, tel qu'écrit	lignes
Essence · essence · ESSENCE · Essence 	51 · 3 · 2 · 1
Diesel · DIESEL · diesel	31 · 1 · 1
Hybride · HYBRIDE · hybride	28 · 4 · 2
Électrique · Electrique	8 · 1
Gazole · Gasoil	1 · 1
(vide)	5

14 écritures, 17 lignes mal écrites.

Gazole ? Gasoil ?

C'est du **Diesel**. Aucune règle d'écriture ne le devine : il faut **connaître le métier**.

Le code, on peut le déléguer.
Savoir ce que veulent dire les données, non.

Les nombres écrits comme du texte

	kilometrage	prix
2	30159	12400
3	145 395 km	3400
8	80874	9 000 €

Excel range **les nombres à droite, le texte à gauche**. Calé à gauche, un « nombre » est lu comme du texte.

- `=MOYENNE()` l'ignore **sans rien dire** ;
- trié, "9 000 €" passe après "77000", parce que « 9 » vient après « 7 ».

Décision : enlever les espaces, km et €, puis lire le reste comme un nombre. 9 kilométrages, 6 prix.

Maintenant, ce sont de vrais nombres. **On peut enfin les regarder.**

PARTIE 3

Lire une colonne : les distributions

D'abord, quelle sorte de colonne ?

Sorte	Ce que c'est	Dans le fichier
Numérique continue	une mesure, qui peut prendre n'importe quelle valeur	prix, kilometrage, remise
Numérique discrète	un compte, des valeurs entières	annee
Catégorielle nominale	des étiquettes, sans ordre	agence, marque, modele, carburant
Catégorielle ordinale	des étiquettes, avec un ordre	etat : Mauvais < Correct < Bon < Très bon
Identifiant	un nom propre, unique par ligne	ref

Cette distinction décide de tout le reste de la séance : comment on résume une colonne, comment on repère ses valeurs aberrantes, comment on la donne à la machine.

133 prix. Qu'en dites-vous ?

13 400 · 12 400 · 3 400 · 2 500 · 11 000 · 3 100 · 9 000 · 12 800 · 7 500 · 5 100 · 16 500 · 4 900 · 4 800 · 11 300 · 12 200 · 13 800 · 11 500 · 18 100 · 26 000 · 3 300 · 5 500 · 7 200 · 3 700 · 17 200 · 4 500 · 8 700 · 9 700 · 22 400 · 6 200 · 3 000 · 8 100 · 17 000 · 10 300 · 4 600 · 19 600 · 9 300 · 12 100 · 15 600 · 18 900 · 24 400 · 14 000 · 5 200 · 13 000 · 8 800 · 17 700 · 3 500 · 6 300 · 2 500 · 15 400 · 8 600 · 4 200 · 6 400 · 17 000 · 8 700 · 3 600 · 3 900 · 14 900 · 2 800 · 26 700 · 9 300 · 13 500 · 3 800 · 12 300 · 9 800 · 3 300 · 14 100 · 15 200 · 20 600 · 13 200 · 3 500 · 23 800 · 5 700 · 6 700 · 7 300 · 7 100 · 20 800 · 2 500 · 8 400 · 5 000 · 7 300 · 16 300 · 32 000 · 7 600 · 5 000 · 4 100 · 9 900 · 12 100 · 8 900 · 11 300 · 4 900 · 4 500 · 5 400 · 11 400 · 5 500 · 8 200 · 12 800 · 8 000 · 3 800 · 6 600 · 8 800 · 4 500 · 3 200 · 5 800 · 19 400 · 2 700 · 18 100 · 9 400 · 8 200 · 8 300 · 18 900 · 8 500 · 3 500 · 18 700 · 5 400 · 2 500 · 8 200 · 2 500 · 9 800 · 7 900 · 11 200 · 24 300 · 30 900 · 11 700 · 3 400 · 3 100 · 6 100 · 12 200 · 4 200 · 11 500 · 8 500 · 10 100 · 11 900 · 9 600

Un prix « normal », c'est combien ? Où sont la plupart des voitures ?

Prendre les valeurs, et les ranger

Les 15 prix de l'extrait, une fois nettoyés :

13 400 · 12 400 · 3 400 · 2 500 · 11 000 · 3 100 · 9 000 · 12 800 · 7 500 · 5 100
· 16 500 · 4 900 · 4 800 · 11 300 · 12 200

Rangés du plus petit au plus grand :

2 500 · 3 100 · 3 400 · 4 800 · 4 900 · 5 100 · 7 500 · **9 000** · 11 000 · 11 300 ·
12 200 · 12 400 · 12 800 · 13 400 · 16 500


Déjà, on lit quelque chose : le plus petit, le plus grand, et celui du milieu (le 8^e, 9 000 €).

Découper en tranches, et compter

Tranche de prix	Les prix qui y tombent	Combien
0 à 3 999 €	2 500 · 3 100 · 3 400	3
4 000 à 7 999 €	4 800 · 4 900 · 5 100 · 7 500	4
8 000 à 11 999 €	9 000 · 11 000 · 11 300	3
12 000 à 15 999 €	12 200 · 12 400 · 12 800 · 13 400	4
16 000 à 19 999 €	16 500	1

Ce tableau s'appelle un **tableau de fréquences**. Toutes les tranches ont la même largeur, et chaque valeur tombe dans une seule tranche.


Dessiner une barre par tranche



Ce dessin s'appelle un **histogramme**. Ce qu'il montre s'appelle la **distribution** de la colonne : **comment ses valeurs se répartissent**, où il y en a beaucoup, où il y en a peu.

Avec 15 valeurs, la forme est encore floue. Elle se précise avec plus de données.

Avec les 133 prix, la forme apparaît



Beaucoup de voitures bon marché, de moins en moins de chères, et une **longue queue à droite**.

Ce qu'une distribution vous dit, en pratique

- **60 %** des voitures se vendent moins de 10 000 €.
- La moitié du milieu se vend entre **5 000 et 13 000 €**.
- Au-delà de 20 000 €, c'est rare : **10 voitures sur 133**.

Une distribution, c'est aussi une **probabilité**. Si une voiture entre demain dans une agence, elle a environ 6 chances sur 10 de valoir moins de 10 000 €.

Pour Nathalie : combien de trésorerie immobiliser, quel stock viser, quel prix est « suspect ».

Le centre : moyenne ou médiane ?

Moyenne : on additionne tout, on divise par le nombre de valeurs.

Cinq voitures : 3 000 · 4 000 · 5 000 ·
6 000 · 32 000
 $50\,000 \div 5 = \mathbf{10\,000\ €}$

Médiane : on range, on prend celle du milieu.

3 000 · 4 000 · **5 000** · 6 000 · 32 000
 $= \mathbf{5\,000\ €}$

Quatre voitures sur cinq valent moins que la moyenne. **Une seule voiture chère tire la moyenne vers elle.** La médiane ne bouge pas.

Sur nos 133 prix : moyenne **10 062 €**, médiane **8 700 €**. C'est la longue queue qui tire la moyenne vers la droite.

La dispersion : l'écart-type, à la main

Cinq remises de l'extrait. Moyenne : $30 \div 5 = 6$.

remise	écart à la moyenne	écart au carré
5	-1	1
7	+1	1
6	0	0
4	-2	4
8	+2	4

Moyenne des carrés : $10 \div 5 = 2$. Racine : $\sqrt{2} = 1,41$. C'est l'**écart-type**.

L'**écart-type** (σ , sigma) est l'écart **typique** entre une valeur et la moyenne. On passe par les carrés pour que les écarts négatifs n'annulent pas les positifs ; la racine ramène à l'unité de départ.

Les quartiles, à la main


Neuf kilométrages de l'extrait, rangés :

rang	1	2	3	4	5	6	7	8	9
km	15 401	24 800	30 159	43 454	67 042	80 874	96 570	145 395	1 250 000
			Q1		médiane		Q3		

- La **médiane** coupe la liste en deux. Les **quartiles** Q1 et Q3 recoupent chaque moitié en deux.
- Entre Q1 et Q3 : **la moitié du milieu** des voitures.
- Sa largeur, $Q3 - Q1 = 96\,570 - 30\,159 = \mathbf{66\,411\text{ km}}$, s'appelle l'**écart interquartile** (IQR).

Avec 9 valeurs, les quartiles tombent pile sur la 3^e et la 7^e. Sinon, le logiciel prend un point entre deux valeurs : les chiffres bougent un peu, la méthode non.

Les formes que vous croiserez



Uniforme : toutes les valeurs aussi fréquentes


Normale : une cloche symétrique

Asymétrique : une longue queue d'un côté

Bimodale : deux bosses

Le dé, les pièces et les appels sont des simulations. Les prix sont les nôtres.


La normale : la cloche



Nos remises : beaucoup autour de la moyenne (5,9 %), de moins en moins en s'éloignant, **autant à gauche qu'à droite**. Moyenne et médiane (5,8 %) sont presque égales.

On la trouve partout où beaucoup de petites causes s'additionnent : tailles, erreurs de mesure, diamètres de pièces usinées, remises négociées.

La règle 68 – 95 – 99,7



Dans une cloche, **68 %** des valeurs sont à moins d'un écart-type de la moyenne, **95 %** à moins de deux, **99,7 %** à moins de trois.



Nos remises : **68 %** à ± 1 écart-type, **95 %** à ± 2 . Exactement la règle.

En usine : une pièce à plus de 3 écarts-types de la cote visée a 3 chances sur 1 000 d'arriver par hasard. On arrête la machine et on cherche la cause. C'est le principe des cartes de contrôle.

L'asymétrie, l'uniforme, la bimodale

Forme	Ce qu'elle veut dire	En pratique
Asymétrique	beaucoup de petites valeurs, quelques très grandes : prix, kilométrages, salaires	annoncez la médiane ; méfiez-vous des méthodes qui supposent une cloche
Uniforme	tout est aussi fréquent : un dé, un tirage au sort	moyenne et médiane coïncident ; il n'y a pas de valeur « typique »
Bimodale	deux bosses : deux populations mélangées (questions simples et pannes)	la moyenne tombe dans le creux, là où il n'y a personne : séparez les deux groupes

Compter, et attendre



- **Poisson** : combien d'événements dans un intervalle. Pannes par semaine, clients par heure, appels par jour.
- **Exponentielle** : combien de temps avant le prochain. Beaucoup d'attentes courtes, quelques très longues.

Simulations. Utiles pour dimensionner une équipe, un stock de pièces, un service client.

Ce que la forme change

La colonne a la forme...	Son centre	Ses valeurs aberrantes	Sa mise à l'échelle
d'une cloche remise	moyenne	z-score	standardisation
asymétrique prix, kilométrage	médiane	quartiles, en regardant la queue	après avoir traité les extrêmes
à deux bosses	aucun des deux	groupe par groupe	groupe par groupe

Avant de calculer quoi que ce soit sur une colonne : **dessinez son histogramme**. Un coup d'œil, et vous évitez la moitié des erreurs.


DEUX COLONNES ENSEMBLE

La corrélation

Deux colonnes qui bougent ensemble

Voiture	âge (ans)	kilométrage (milliers)
A	1	10
B	2	35
C	3	30
D	4	60
E	5	55


Cinq voitures inventées.



Plus une voiture est vieille, plus elle a roulé, en général. Pas toujours (C a moins roulé que B), mais la tendance est nette.

Deux colonnes sont **corrélées** quand connaître l'une renseigne sur l'autre : elles montent ensemble, ou l'une monte quand l'autre descend. Le dessin, où chaque point est une voiture, s'appelle un **nuage de points**.

Le coefficient de corrélation, r



- r va de **-1** à **+1**.
- Le **signe** donne le sens : + elles montent ensemble ; - l'une monte quand l'autre descend.
- La **valeur** donne la force : près de 1 (ou de -1), les points forment presque une ligne droite ; près de 0, aucun lien en ligne droite.

$ r $	au-dessus de 0,9	0,7 à 0,9	0,3 à 0,7	sous 0,3
on dit	presque jumelles	forte	moyenne	faible

Des repères, pas des lois.

Calculer r à la main


r = la moyenne des produits des z-scores. Âge : moyenne 3, écart-type 1,41. Kilométrage : moyenne 38, écart-type 18,06.

Voiture	âge	z âge	km	z km	produit
A	1	-1,41	10	-1,55	+2,19
B	2	-0,71	35	-0,17	+0,12
C	3	0	30	-0,44	0
D	4	+0,71	60	+1,22	+0,86
E	5	+1,41	55	+0,94	+1,33

Somme des produits : 4,50. Divisée par 5 : **r = 0,90.**

Les deux au-dessus de leur moyenne, ou les deux en dessous : produit **positif**. L'un au-dessus, l'autre en dessous : produit **négatif**. r fait le bilan.

Dans notre fichier



la matrice de corrélation

annee	1,00	-0,83	0,00	0,82
kilometrage	-0,83	1,00	0,14	-0,74
remise	0,00	0,14	1,00	0,02
prix	0,82	-0,74	0,02	1,00
	annee	kilometrage	remise	prix

- **année et kilométrage, $-0,83$** : une voiture récente a peu roulé.
- **année et prix, $+0,82$; kilométrage et prix, $-0,74$.**
- **la remise** n'a de lien avec rien : autour de 0.

Avec les valeurs aberrantes encore dedans, année et kilométrage ne valaient que $-0,49$: quelques erreurs suffisent à cacher un lien.

Deux colonnes qui disent la même chose

Voiture	puissance (ch)	puissance (kW)
A	75	55
B	100	74
C	130	96
D	180	132
E	225	165

$r = 1,00$. Une colonne est l'autre multipliée par 0,7355.

D'autres jumelles, fréquentes dans les fichiers d'entreprise :

- le prix HT et le prix TTC : $r = 1$;
- l'année et l'âge de la voiture : $r = -1$;
- des kilomètres et des miles.

La deuxième colonne n'apporte **aucune information** : c'est la première, dans une autre unité.

Pourquoi n'en garder qu'une

1. **La même information, comptée deux fois.** C'est un doublon, mais en colonne : la puissance pèse deux fois plus que le reste.
2. **Le modèle ne sait pas partager le mérite.** « 40 € par ch », « 54 € par kW », ou « 200 € par ch moins 218 € par kW » donnent exactement les mêmes prix. Le modèle en prend une au hasard des données : son explication devient absurde (« plus de kW, prix plus bas ») et change d'un fichier à l'autre.
3. **Plus de colonnes, c'est plus de calcul,** plus de risque d'apprendre par cœur, et un modèle plus dur à expliquer.

Laquelle garder ? La plus facile à obtenir, la moins souvent vide, la plus parlante pour le métier. Repère : au-delà de $|r| = 0,9$ entre deux caractéristiques, on n'en garde qu'une.

Année et kilométrage ($-0,83$) : liées, mais pas jumelles. Une voiture de 2015 peut avoir 70 000 ou 200 000 km, et son prix en dépend : on garde les deux.

Quand plusieurs caractéristiques sont très corrélées entre elles, on parle de **multicolinéarité**.

Trois précautions

Précaution	Pourquoi
Corrélée à la cible : c'est une bonne nouvelle	Kilométrage et prix ($-0,74$) : c'est justement ce que le modèle doit apprendre. On ne supprime jamais une colonne parce qu'elle est liée à la cible.
Corrélation n'est pas causalité	Les ventes de glaces et les noyades montent ensemble. Les glaces ne noient personne : c'est la chaleur qui fait monter les deux.
r ne voit que les lignes droites	La consommation d'une voiture est forte à très basse vitesse et à très haute vitesse : un lien en U, qui peut donner r proche de 0. Dessinez toujours le nuage.

PAUSE

Pause

Ensuite : les valeurs aberrantes, l'encodage, la mise à l'échelle.

PARTIE 4 · ÉTAPE 5

Les valeurs aberrantes

Une valeur loin des autres


	modele	annee	kilometrage	remise	prix
9	Yaris	2031	24800	6,2	11200
12	Sandero	2024	7531	5,8	1
14	Mégane	2015	1250000	6,6	5100
17	Sandero	2019	66355	48,0	4800
18	208	2019	61240	7,1	77000

Deux sortes de valeurs aberrantes :

L'erreur : impossible. Une faute de frappe, un prix provisoire. 2031, 1 €, 48 % de remise.

La rare, mais vraie : un 3008 hybride neuf à 32 000 €. La supprimer, c'est cacher la réalité au modèle.

Première défense : le métier



Des bornes fixées **avec Nathalie**, pas calculées : année au plus 2025 ; au plus 500 000 km ; prix entre 1 000 et 50 000 € ; remise au plus 30 %.

Les bornes attrapent l'**impossible**. Pour le **suspect**, il faut une méthode : on en voit deux.

Le z-score

« À combien d'écart-types de la moyenne est cette valeur ? »

$$z = (\text{valeur} - \text{moyenne}) \div \text{écart-type}$$

Sur nos cinq remises (moyenne 6, écart-type 1,41) :

la remise de 8 % $\rightarrow (8 - 6) \div 1,41 = \mathbf{z = 1,41}$.
Normal.

Sur les 140 remises (moyenne 6,23, écart-type 3,85) :

la remise de 48 % $\rightarrow (48 - 6,23) \div 3,85 = \mathbf{z = 10,8}$. Alerte.

La règle : au-delà de **$z = 3$** (ou en dessous de -3), on signale. Pourquoi 3 ? Parce que dans une cloche, 99,7 % des valeurs sont à moins de 3 écart-types.

Les quartiles (la règle de Tukey)


On reprend les neuf kilométrages : $Q1 = 30\ 159$, $Q3 = 96\ 570$, $IQR = 66\ 411$.

Borne	Calcul	Résultat
haute	$Q3 + 1,5 \times IQR = 96\ 570 + 99\ 617$	196 187 km
basse	$Q1 - 1,5 \times IQR = 30\ 159 - 99\ 617$	négative : aucune

1 250 000 km dépasse la borne haute : **signalé**. 145 395 km reste dedans : normal.

Pourquoi 1,5 ? C'est le choix de John Tukey, le statisticien qui a inventé la méthode. Sur une cloche, ces bornes tombent à environ 2,7 écarts-types.

Lire une boîte à moustaches



- La **boîte** va de Q1 à Q3 : la moitié du milieu. Le trait vert est la médiane.
- Les **moustaches** s'arrêtent à la dernière valeur avant les bornes de Tukey.
- Les **points** au-delà sont signalés. Ici : quatre voitures entre 26 000 et 32 000 €.

Ces quatre voitures sont des C-HR et des 3008 de 2024. Elles sont chères, et vraies.

Le duel, sur neuf valeurs

Quartiles

borne haute 196 187 km
1 250 000 km → **signalé**

z-score

moyenne 194 855, écart-type 375 046
 $z = (1\,250\,000 - 194\,855) \div 375\,046 = \mathbf{2,81}$
→ **pas signalé**

Pourquoi ? La valeur fausse **gonfle elle-même** la moyenne et l'écart-type qui servent à la juger. Elle se cache derrière elle-même.

Pire : avec 9 valeurs, **aucun z-score ne peut dépasser 2,83**, quelle que soit la valeur. Avec moins de 10 valeurs, la règle « $z > 3$ » ne signale jamais rien.

Le duel, sur tout le fichier

Colonne	z-score > 3	Quartiles (1,5 × IQR)	Bornes métier
remise cloche	48 %, seule	48 %, et 2,1 % et 9,8 %, vraies	48 %
prix asymétrique	77 000 €	77 000 €, et 4 voitures chères, vraies	77 000 €, 1 €, 1 €
kilométrage asymétrique	1 250 000	1 250 000, et 245 277, vraie	1 250 000

- Sur 140 valeurs, le z-score retrouve l'erreur : il y a assez de données pour qu'elle ne se cache plus.
- Les quartiles signalent aussi la **queue naturelle** : des valeurs rares, mais vraies.
- **Aucune méthode statistique ne voit les prix à 1 €** ($z = -1,2$). Seul le métier les voit.

Quand utiliser quoi

Méthode	À utiliser quand...	Son défaut
z-score	la colonne a la forme d'une cloche , et il y a beaucoup de valeurs (au moins quelques dizaines)	les valeurs extrêmes faussent la moyenne et l'écart-type qui les jugent
Quartiles	la forme est inconnue ou asymétrique , l'échantillon est petit , on craint plusieurs extrêmes	signale la queue naturelle d'une distribution asymétrique
Bornes métier	toujours , en premier	ne voit que l'impossible, pas le suspect

On regarde d'abord l'histogramme. La forme choisit la méthode.

Détecter n'est pas supprimer

La valeur signalée est...	Décision
impossible : 2031, 1 €, 1 250 000 km, 48 %, 77 000 €	vider la case , sans deviner la bonne valeur ; elle sera traitée à l'étape 6
rare, mais vraie : le 3008 à 32 000 €, la 308 à 245 277 km	garder : c'est la réalité que le modèle doit apprendre
on ne sait pas	demander à l'agence ; à défaut, on peut plafonner (ramener à la borne)

2031 : 2021 ? 2013 ? On n'en sait rien. **Corriger au jugé, c'est inventer une donnée.**
Une case vide est honnête.

Dans le fichier : 6 valeurs vidées (1 année, 1 kilométrage, 3 prix, 1 remise).

Les cases vides : quatre façons

Après l'étape 5 : carburant 5, année 1, kilométrage 9, remise 1, prix 6.

Façon	Quand	Le prix à payer
Supprimer la ligne	c'est la cible, ou c'est très rare	on perd toute la vente
Remplir par la moyenne ou la médiane	une colonne numérique, quelques cases	on invente un peu
Écrire « Inconnu »	une colonne catégorielle	une catégorie de plus
Ajouter une colonne « était vide » (0 ou 1)	quand l'absence elle-même peut dire quelque chose	une colonne de plus

Une décision par colonne

Colonne	Décision	Pourquoi
prix	supprimer la ligne	c'est la cible. On ne remplit jamais la réponse que le modèle doit apprendre.
annee	supprimer la ligne	une seule ligne
kilometrage	médiane , 72 736 km	distribution asymétrique : la moyenne (81 590) serait tirée par la queue
remise	médiane , 5,8 %	une cloche : moyenne (5,9) et médiane se valent
carburant	« Inconnu »	catégorielle : on garde la vente, sans inventer

140 → 133

PARTIE 5 · ÉTAPE 7

Des mots en nombres : encoder

Ce que la machine comprend

Des nombres. Rien d'autre.

Et d'un nombre, elle ne sait que deux choses :

1. **lequel est le plus grand** : 4 est plus grand que 2 ;
2. **de combien** : 4, c'est deux fois 2, et 2 de plus.

Tout ce que vous lui donnez sous forme de nombre, **elle le croit**. Si vous écrivez un nombre qui ment, elle apprend le mensonge.

Encoder, c'est traduire les mots en nombres **sans lui mentir**.

La question à se poser : y a-t-il un ordre ?

Nominale : aucun ordre

Essence, Diesel, Hybride, Électrique. Est-ce que Diesel est « plus » qu'Essence ? La question n'a pas de sens.

Ordinale : un ordre naturel

Mauvais < Correct < Bon < Très bon.
Personne ne discute que Bon est mieux que Correct.

État	Prix médian dans le fichier
Mauvais	3 500 €
Correct	6 700 €
Bon	9 450 €
Très bon	12 400 €

L'ordre de l'état se voit dans les prix. Il porte de l'information : il faut la garder.

L'état : un nombre qui respecte l'ordre

	etat	→	etat_code
4	Mauvais		0
7	Correct		1
1	Bon		2
2	Très bon		3

Une seule colonne. Et les nombres disent vrai : 3 est au-dessus de 2, comme Très bon est au-dessus de Bon.

La machine peut apprendre en une fois : « plus l'état monte, plus le prix monte ».

Le piège : la machine croit aussi que les marches sont **égales**. Ici, c'est à peu près vrai : +3 200, +2 750, +2 950 € d'une marche à l'autre. Si l'écart entre Bon et Très bon valait dix fois les autres, l'encodage ordinal mentirait un peu.

Et pour le carburant, pourquoi pas 1, 2, 3, 4 ?

Essence = 1, Diesel = 2, Hybride = 3, Électrique = 4.

La machine lit des nombres. Elle en conclut que...

- l'électrique vaut **quatre fois** l'essence ;
- l'hybride est **entre** le diesel et l'électrique ;
- deux essences font un diesel.

Des nombres inventent un ordre qui n'existe pas. Et changer l'ordre alphabétique changerait ce que le modèle apprend : c'est le signe que ces nombres ne veulent rien dire.

Une colonne par valeur, avec 1 ou 0

	carburant
1	Diesel
3	Essence
8	Hybride
15	Inconnu



	Diesel	Essence	Hybride	Électrique	Inconnu
1	1	0	0	0	0
3	0	1	0	0	0
8	0	0	1	0	0
15	0	0	0	0	1


Chaque colonne répond à une question par oui (1) ou non (0) : « est-ce un diesel ? ». **Aucun ordre, aucune distance inventée.**

En anglais **one-hot** : sur chaque ligne, une seule colonne est « allumée ».

Les pièges du one-hot

Situation	Ce qui se passe	Que faire
Beaucoup de valeurs : 14 modèles	14 colonnes, presque toutes à 0	acceptable ; au-delà de quelques dizaines, regrouper les rares en « Autre »
Un identifiant : <code>ref</code>	133 colonnes, une par vente. Le modèle apprend les ventes par cœur	jamais : un identifiant n'est pas une caractéristique
Une valeur nouvelle : demain, une voiture au GPL	aucune colonne ne l'attend	prévoir une colonne « Autre » ou « Inconnu »
Une ordinale en one-hot : l'état	ça marche, mais la machine doit réapprendre l'ordre seule, avec moins d'exemples par colonne	préférer l'ordinal

Quand utiliser quoi



La règle, en une ligne : **quand l'ordre compte, un seul nombre qui le respecte ; sinon, une colonne par valeur.**

Exercice éclair : ordinal, one-hot, ou rien ?

Colonne	Réponse
Agence : Montbéliard, Belfort, Besançon	one-hot
Taille de vêtement : S, M, L, XL	ordinal
Couleur de la carrosserie	one-hot
Satisfaction : déçu, moyen, content, ravi	ordinal
Code postal : 25200, 90000, 25000	one-hot, surtout pas comme un nombre : Belfort ne vaut pas 3,6 fois Montbéliard
Référence de la vente V-0042	rien : c'est un identifiant

PARTIE 6 · ÉTAPE 8

La même échelle pour tous : normaliser ou standardiser

Pourquoi : une question de distance

Beaucoup de méthodes cherchent les voitures **qui se ressemblent**.
Laquelle ressemble le plus à A ?

Voiture	année	kilométrage
A	2019	60 000
B	2015	62 000
C	2019	70 000

Votre intuition : **C**, même âge, un peu plus roulée. B a quatre ans de plus.

Le calcul brut : distance A–B = $\sqrt{4^2 + 2\,000^2} \approx \mathbf{2\,000}$; distance A–C = $\sqrt{0^2 + 10\,000^2} = \mathbf{10\,000}$.

La machine répond B. Quatre ans comptent autant que 4 kilomètres : les kilomètres écrasent tout, **juste parce que leurs nombres sont plus grands**.

Ramener entre 0 et 1

valeur normalisée = $(\text{valeur} - \text{minimum}) \div (\text{maximum} - \text{minimum})$

Sur nos cinq remises (minimum 4, maximum 8, écart 4) :

remise	calcul	normalisée
4	$(4 - 4) \div 4$	0
5	$(5 - 4) \div 4$	0,25
6	$(6 - 4) \div 4$	0,5
7	$(7 - 4) \div 4$	0,75
8	$(8 - 4) \div 4$	1

0 pour la plus petite valeur, 1 pour la plus grande, et le reste à sa place entre les deux. En anglais : min-max scaling.

Centrer sur 0, avec un écart-type de 1

valeur standardisée = (valeur - moyenne) ÷ écart-type

Les mêmes cinq remises (moyenne 6, écart-type 1,41) :

remise	calcul	standardisée
4	$(4 - 6) \div 1,41$	-1,41
5	$(5 - 6) \div 1,41$	-0,71
6	$(6 - 6) \div 1,41$	0
7	$(7 - 6) \div 1,41$	+0,71
8	$(8 - 6) \div 1,41$	+1,41

Vous reconnaissez la formule : **c'est le z-score**. Standardiser, c'est remplacer chaque valeur par son z-score.

Côte à côte

	Normalisation	Standardisation
Calcul	$(x - \min) \div (\max - \min)$	$(x - \text{moyenne}) \div \text{écart-type}$
Résultat	entre 0 et 1	moyenne 0, écart-type 1, pas de bornes
Change la forme de la distribution ?	non	non
Une nouvelle valeur plus grande que le max	dépasse 1	aucun problème
Une valeur extrême dans les données	écrase toutes les autres vers 0	les écrase moins

Idée fausse fréquente : standardiser ne rend pas une distribution « normale ». Une distribution asymétrique reste asymétrique. On change l'unité, pas la forme.

Retour aux voitures A, B, C

On normalise avec les bornes du fichier : année de 2013 à 2024 (écart 11), kilométrage de 4 050 à 245 277 (écart 241 227).

	écart d'année	écart de km	distance
A – B	$4 \div 11 = 0,36$	$2\,000 \div 241\,227 = 0,008$	0,36
A – C	0	$10\,000 \div 241\,227 = 0,041$	0,04

Maintenant, **C est la plus proche**. Chaque colonne pèse selon ce qu'elle dit, plus selon son unité.

Et avec une valeur extrême ?

Les kilométrages **avant** d'avoir vidé le 1 250 000 :

	Les 131 autres voitures tombent entre...	La valeur extrême
Normalisation	0 et 0,19 : toutes serrées au fond	1
Standardisation	−0,75 et 1,36	10,2
Après avoir traité la valeur extrême	normalisation : 0 et 1 · standardisation : −1,53 et 3,27	–

Une seule valeur fausse suffit à écraser toute une colonne. **On traite les valeurs aberrantes avant de mettre à l'échelle** : c'est pour ça que l'étape 5 vient avant l'étape 8.

Quand utiliser quoi

Choisir...	quand
la standardisation	la colonne a la forme d'une cloche ; des valeurs extrêmes restent possibles ; on cherche des groupes (clustering)
la normalisation	on veut des valeurs bornées entre 0 et 1 ; les bornes sont connues et fixes (les pixels d'une image, de 0 à 255) ; pas de valeur extrême
ni l'une ni l'autre	les arbres de décision : ils comparent chaque colonne à un seuil, une à la fois, et l'unité ne change rien

En cas de doute, la standardisation est le choix par défaut le plus sûr. Et quand vous hésitez vraiment : essayez les deux, et comparez les résultats du modèle.

Le piège de la voiture de demain

Demain, une voiture arrive avec **300 000 km**. On ne peut pas recalculer un minimum ou une moyenne sur une seule voiture !

- On garde les paramètres appris sur le fichier : min 4 050, max 245 277, moyenne 80 991, écart-type 50 283.
- Normalisée : $(300\ 000 - 4\ 050) \div 241\ 227 = \mathbf{1,23}$: au-delà de 1.
- Standardisée : $(300\ 000 - 80\ 991) \div 50\ 283 = \mathbf{4,36}$: très loin, mais lisible.

Règle : minimum, maximum, moyenne et écart-type se calculent **une fois**, sur les données d'apprentissage, et s'appliquent **tels quels** aux données nouvelles.

Questions 1 et 2

Problème	Colonnes	Exemple	Combien	Que faire
Doublons	toutes	ligne 13 = ligne 4	6	supprimer la copie
Écrit de plusieurs façons	agence, marque, carburant, état	Montbeliard, Citroen, Gazole, Tres bon	14 · 4 · 17 · 3	harmoniser avec une table de correspondance
Nombres en texte	kilometrage, prix	145 395 km, 9 000 €	9 · 6	convertir en nombres
Valeurs aberrantes	annee, kilometrage, remise, prix	2031, 1 250 000 km, 48 %, 1 €, 77 000 €	1 · 1 · 1 · 3	impossibles : vider la case · rares mais vraies : garder
Cases vides	prix, annee, kilometrage, remise, carburant	lignes 5, 9, 10, 15, 17	6 · 1 · 9 · 1 · 5	prix, année : supprimer · km, remise : médiane · carburant : « Inconnu »

Question 3, et ce qu'elle n'a pas demandé

146

lignes reçues

140

sans les doublons

133

ventes utilisables

Neuf écritures pour trois agences : le vrai problème est la **saisie libre**.

Nettoyer 2025 ne sert à rien si 2026 arrive dans le même état.

La recommandation : des listes déroulantes pour l'agence, la marque, le carburant et l'état, et des cellules qui n'acceptent que des nombres. Excel : Données → Validation des données → Liste.

Ce qu'il faut retenir

1. Un modèle apprend ce qu'on lui montre, **erreurs comprises**.
2. Avant tout calcul, **dessinez la distribution** : sa forme choisit le centre, la méthode, l'échelle.
3. Valeurs aberrantes : **z-score** pour les cloches bien remplies, **quartiles** sinon, **le métier** toujours. Détecter n'est pas supprimer.
4. Deux caractéristiques jumelles ($|r| > 0,9$) : **on n'en garde qu'une**. Liée à la cible : on la garde.
5. Encoder : un ordre naturel → **ordinal** ; pas d'ordre → **one-hot** ; un identifiant → rien.
6. Mettre à l'échelle : **standardiser** par défaut, **normaliser** quand les bornes sont connues, et toujours **après** les valeurs aberrantes.
7. **On ne devine pas** : on décide, et on note.

EN PRATIQUE

Installer Jupyter

Suivez `install-jupyter.pdf`, sur la page GitHub du cours

On n'installe rien dans le Python de votre ordinateur

Le Python du système

Celui de macOS, de Linux, ou celui installé un jour sur Windows. D'autres programmes s'en servent. **On n'y touche pas.**

Le dossier `ia-elc2`

`.venv` : un Python à part, et les bibliothèques du cours.

`requirements.txt` : la liste de ces bibliothèques.

vos notebooks et vos données.

Un **environnement virtuel** (`.venv`) est une trousse rangée dans le dossier du cours : son propre Python, ses propres bibliothèques. Supprimez le dossier : les bibliothèques partent avec lui, et le Python du système n'a jamais été touché.

Le fichier **requirements.txt** est la liste des courses : quelles bibliothèques, en quelle version. Tout le monde installe la même chose.

Les commandes

Après avoir installé `uv` (étape 2 du guide, selon votre système) et placé le dossier `ia-elc2` dans votre dossier personnel :

```
cd ~/ia-elc2
uv venv --python 3.13
uv pip install -r requirements.txt
uv run jupyter notebook
```

`cd ~/ia-elc2`

entrer dans le dossier du cours

à chaque fois

`uv venv`

créer la trousse `.venv`

une seule fois

`uv pip install -r requirements.txt`

la remplir avec la liste

une seule fois

`uv run jupyter notebook`

lancer Jupyter **avec** la trousse

à chaque fois

Le premier notebook

Ouvrez `01-premier-notebook.ipynb`. Puis, cellule après cellule, **Maj + Entrée**.

- La cellule 0 vérifie que vous êtes bien dans `.venv`.
- Parties 1 à 4 : l'extrait, les doublons, les écritures, les nombres en texte.
- Un seul endroit à compléter : **À vous**. Que valent Gazole et Gasoil ?
- Parties 5 à 10 : distributions, valeurs aberrantes, cases vides, corrélation, encodage, mise à l'échelle. Chaque chiffre de ce cours y ressort.

Avant de partir

Menu **Run** → **Run All Cells**. Sur **votre propre écran** :

OK : ce notebook tourne dans l'environnement virtuel du cours.

et, dans la partie 7, la réponse à Nathalie :

133

Pas fini ? Terminez chez vous avec le guide. En cas de blocage, le plan B (Google Colab) permet de suivre la prochaine séance sans rien installer.

ANNEXES

Pour aller plus loin

Non projetées. À lire chez soi, ou à utiliser si la séance avance vite.

Trois dates suffisent

1956	Un atelier d'été à Dartmouth, aux États-Unis, lance le nom « intelligence artificielle ».
2012	Un réseau de neurones gagne très largement un concours de reconnaissance d'images (ImageNet). Le deep learning décolle.
2022	ChatGPT sort fin novembre. Environ 100 millions d'utilisateurs en deux mois : l'IA arrive chez tout le monde.

En 2024, deux prix Nobel récompensent l'IA : physique pour les réseaux de neurones (Hopfield, Hinton), chimie pour la prédiction des protéines (Hassabis, Jumper, Baker).

Depuis 2022, ce qui a changé

- **Tout le monde y a accès**, gratuitement, dans un navigateur.
- **Des modèles ouverts**, que chacun peut télécharger. Dont un français : Mistral AI, fondée à Paris en 2023.
- **Des IA qui agissent** : elles utilisent des outils, remplissent un tableau, écrivent et exécutent du code. On les appelle des *agents*.
- **Texte, image, voix, vidéo**, dans un même modèle.

Ce que l'IA fait mal

- **Elle invente, avec assurance.** Une référence, un chiffre, une loi qui n'existent pas : une **hallucination**.
- **Elle reproduit les défauts de ses données** : un **biais**.
- **Elle consomme beaucoup d'énergie**, surtout les très gros modèles.
- **Elle ne sait pas quand elle ne sait pas.**

Et la loi ?

Le **règlement européen sur l'IA** (*AI Act*) est en vigueur depuis août 2024, et s'applique par étapes, sur plusieurs années.

Risque	Exemples	Ce que dit la loi
Inacceptable	notation sociale des citoyens	interdit depuis février 2025
Élevé	recrutement, crédit, éducation, santé	obligations strictes, dont la qualité des données
Limité	un chatbot, une image générée	dire que c'est une IA
Minimal	filtre anti-spam, jeu vidéo	rien de particulier

Et ChatGPT, dans tout ça ?

Le même principe, à une échelle énorme : il a appris, sur des milliards de phrases, à deviner **le mot suivant**.

Il ne cherche pas ce qui est vrai. Il cherche la suite la plus probable. D'où les hallucinations.

Comment savoir si un modèle est bon ?

Comme un examen : **avec des questions qu'on n'a jamais vues.**

1. On met de côté une partie des ventes, par exemple une sur cinq.
2. Le modèle apprend sur les autres.
3. On lui demande le prix des ventes mises de côté, et on compare aux vrais prix.

Quand un modèle récite ses exemples mais se trompe sur les nouveaux, on parle de **surapprentissage** (en anglais overfitting).

Et l'IA, elle ne pourrait pas nettoyer à ma place ?

Oui, pour écrire le code.

« Voici les colonnes de mon fichier. Écris le code Python qui retire les doublons et met les agences au propre. » Elle le fait très bien.

Non, pour décider.

Gazole = Diesel ? 1 €, provisoire ou vrai prix ? Supprimer ou remplir ? Elle proposera quelque chose, avec assurance. Peut-être faux.

Le code, vous pouvez le déléguer.
Les décisions, c'est vous qui les signez.