La régression

Prédire un nombre à partir de ce qu'on connaît

Joseph Azar

Maître de conférences
Université Marie et Louis Pasteur
ELC2 · Introduction au machine learning · Séance 3

Plan

1. Prédire un nombre : de quoi parle-t-on ?
2. Une droite à travers les points, calculée à la main sur 5 voitures
3. Mesurer l'erreur : erreur moyenne et R^2
4. Plusieurs caractéristiques à la fois
5. Quand la droite ne suffit plus : la courbe
6. Les pièges, puis le code Python

🍕 Vous le faites déjà

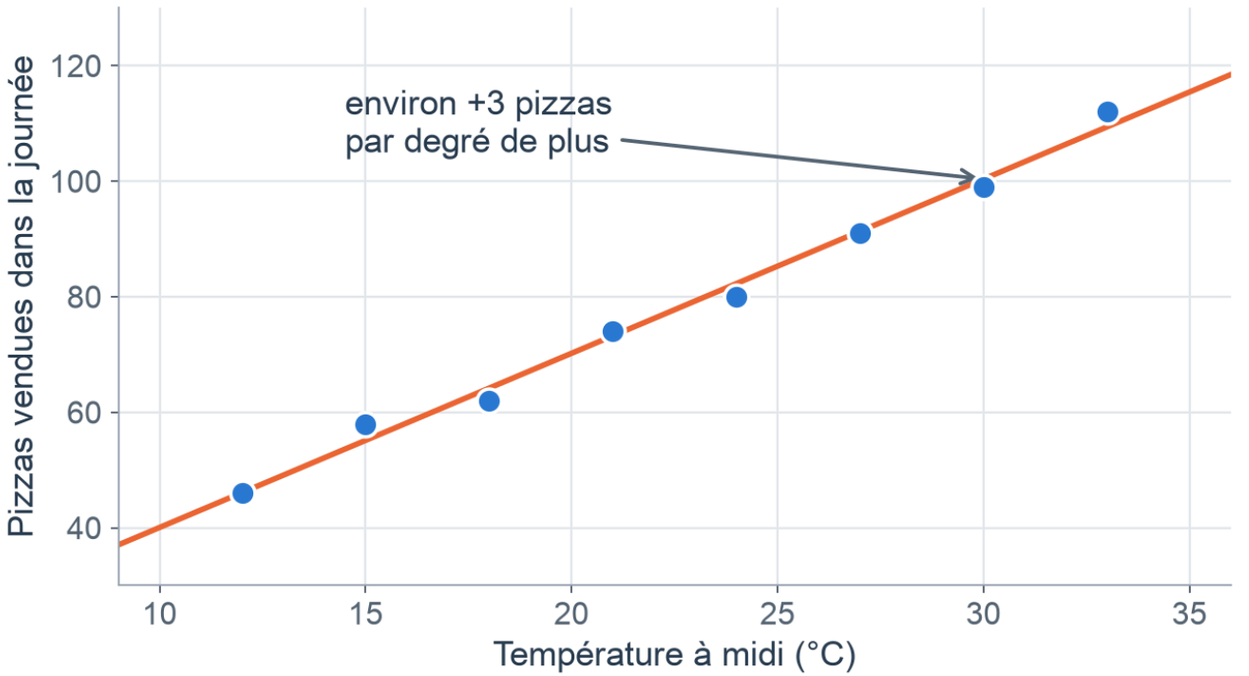
Marco, pizzaiolo à Besançon.

Plus il fait chaud, plus il vend de pizzas.

Demain : 27 °C. Combien de pizzas préparer ?

Vous venez de tracer **une droite dans votre tête**.

La régression la trace pour vous, par le calcul.



8 journées de Marco · chiffres inventés

🚗 Retour chez Nathalie

En séance 1, vous avez préparé le fichier de **Comtoise Auto Occasion**. Aujourd'hui, Nathalie veut **estimer le prix** d'une voiture dès son arrivée.

Réf.	Année	Kilométrage	Puissance (ch)	Carburant	État	Prix (€)
V-0001	2017	118 600	75	Diesel	Bon	**3990**
V-0002	2011	142 900	110	Essence	Correct	**1800**
V-0003	2021	46 800	110	Diesel	Bon	**9030**
V-0004	2023	32 200	75	Hybride	Bon	**10800**
V-0005	2021	70 300	110	Essence	Bon	**9750**
V-0006	2019	74 900	90	Diesel	Bon	**6860**

extrait de voitures-comtoise-auto.csv : 500 voitures, fichier propre (séance 1 faite)

Les caractéristiques : ce qu'on connaît
année, kilométrage, puissance, carburant, état

La cible : ce qu'on cherche
le prix. C'est **un nombre**

Régression ou classification ?

La réponse à deviner est **un nombre** : c'est une **régression**.

La réponse est **une catégorie** : c'est une **classification** (séance 2).

La question	La réponse	Le type
Quel est le prix de cette voiture ?	13 400 €	**régression**
Cette voiture partira-t-elle en moins de 30 jours ?	Oui ou Non	**classification**
Combien de temps ce trajet va-t-il durer ?	42 minutes	**régression**
Ce client va-t-il résilier ?	Oui ou Non	**classification**

🌍 Où l'utilise-t-on ?

Commerce

- Le prix d'une course, d'un logement
- Les ventes du mois prochain

Sciences

- La température de demain
- Le niveau de pollution

Santé

- Le dosage d'un médicament
- L'espérance de vie

Finance

- Le prix d'une action
- Le montant d'un crédit

Trois outils aujourd'hui

Régression simple

Une seule caractéristique.
Une **droite**.

prix selon le kilométrage

Régression multiple

Plusieurs caractéristiques.
Un **plan** et au-delà.

prix selon âge, km, état, carburant…

Régression polynomiale

Une **courbe** quand la relation n'est pas droite.

prix selon l'âge

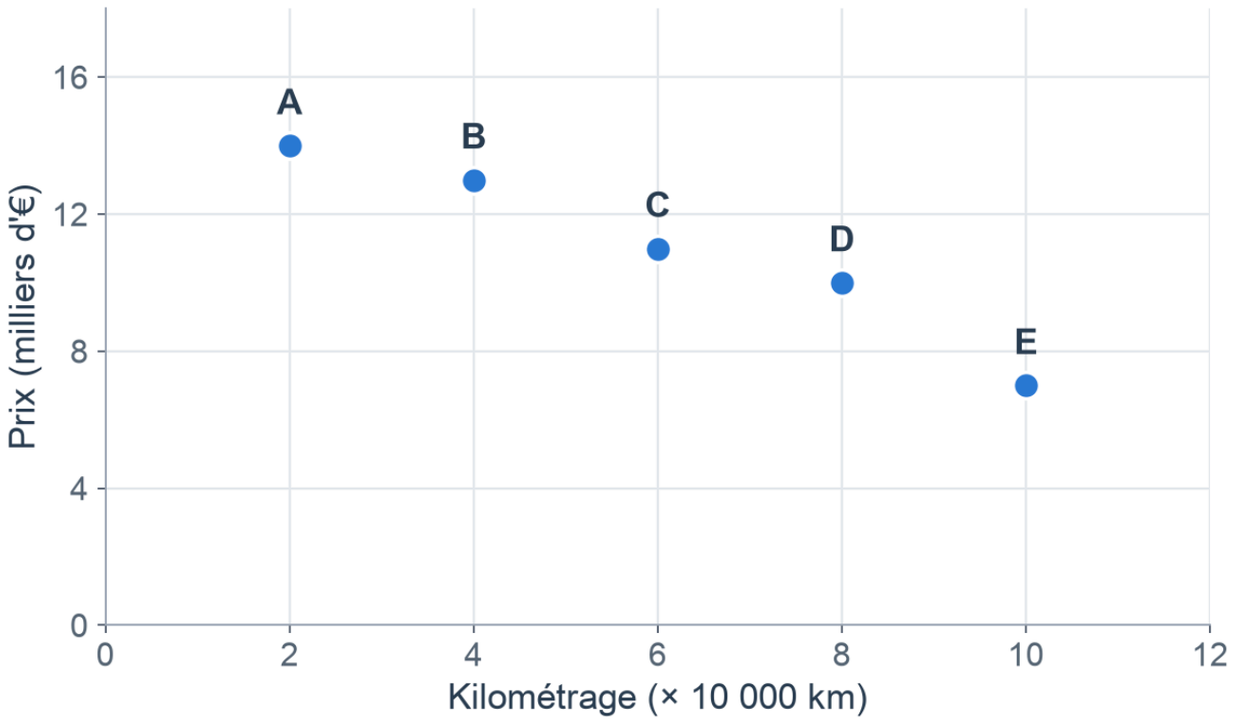
Attention au nom : la **régression logistique** (séance 2) sert à **classer**, pas à prédire un nombre.

📈 La droite, pas à pas

1 Les données | 2 La droite | 3 Le calcul | 4 Prédire | 5 Évaluer

5 voitures, aux chiffres **arrondis** pour calculer à la main.

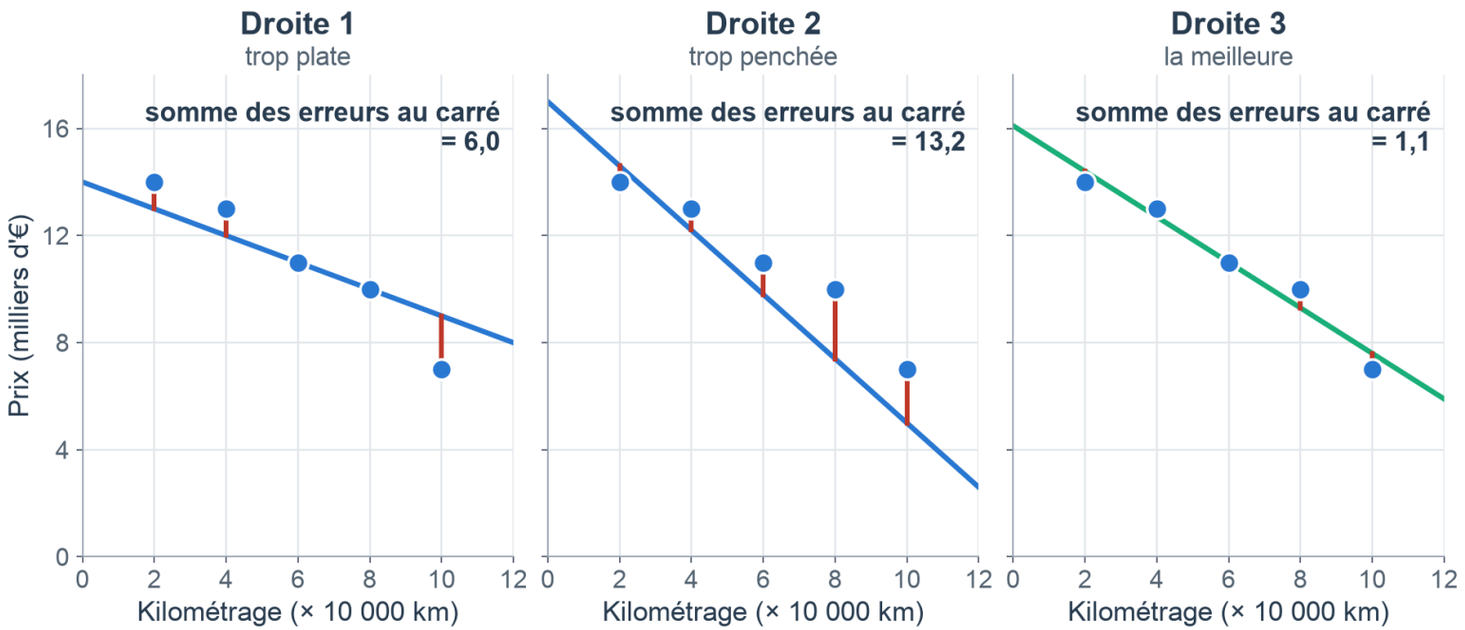
Voiture	Kilométrage (× 10 000 km)	Prix (milliers d'€)
A	2	14
B	4	13
C	6	11
D	8	10
E	10	7



Plus la voiture a roulé, moins elle vaut. Quelle droite résume cela ?

Quelle droite choisir ?

1 Les données | **2 La droite** | 3 Le calcul | 4 Prédire | 5 Évaluer

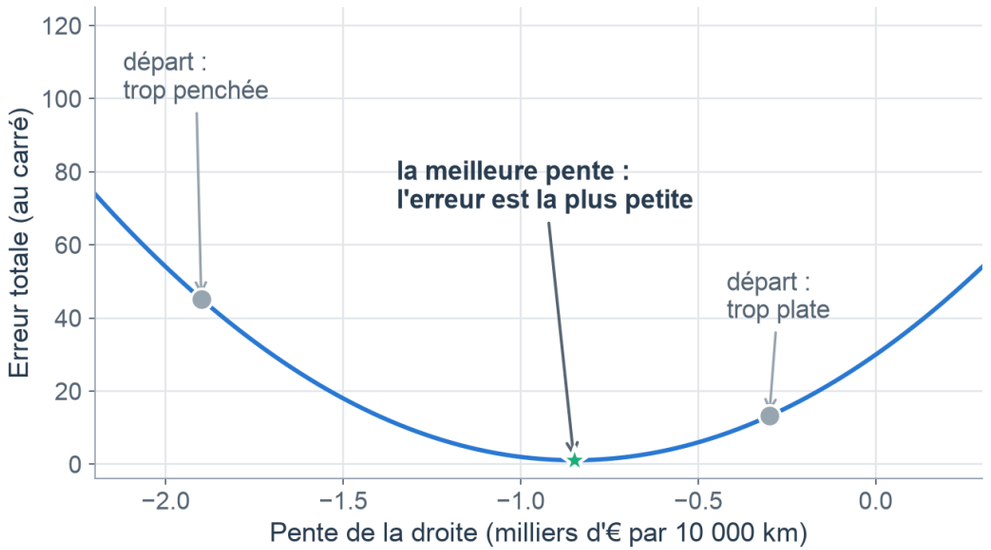


Erreur d'une voiture : l'écart vertical entre le point et la droite (trait rouge).

On met chaque erreur **au carré** (pour que les + et les – ne s'annulent pas, et pour punir les grosses erreurs), puis on additionne. **La meilleure droite : la somme la plus petite.**

⛰️ Le fond de la cuvette

1 Les données | **2 La droite** | 3 Le calcul | 4 Prédire | 5 Évaluer



On fait **varier la pente** de la droite et, pour chaque pente, on calcule la somme des erreurs au carré.

Cela dessine une **cuvette** : grande erreur si la droite est trop plate ou trop penchée.

La meilleure droite est **au fond**.

Pour trouver le fond, une **formule** existe : nous l'appliquerons. Avec beaucoup de caractéristiques, l'ordinateur **descend pas à pas**, comme un randonneur dans le brouillard.

✏️ L'équation d'une droite

$$\text{prix} = a \times \text{kilométrage} + b$$

a : la **pente**

De combien le prix change quand le kilométrage augmente de 1.

b : le **point de départ**

Le prix qu'aurait une voiture à 0 km.

Tout le travail consiste à trouver **a** et **b**. L'ordinateur les cherche ; nous allons les calculer une fois à la main.

🧮 Le calcul (1/6) : les moyennes

Ce qui entre

Les 5 voitures :
kilométrage 2 · 4 · 6 · 8 · 10
prix 14 · 13 · 11 · 10 · 7

→

Ce qu'on fait

La moyenne de chaque colonne.

$\bar{x} = (2 + 4 + 6 + 8 + 10) / 5$
$\bar{y} = (14 + 13 + 11 + 10 + 7) / 5$

→

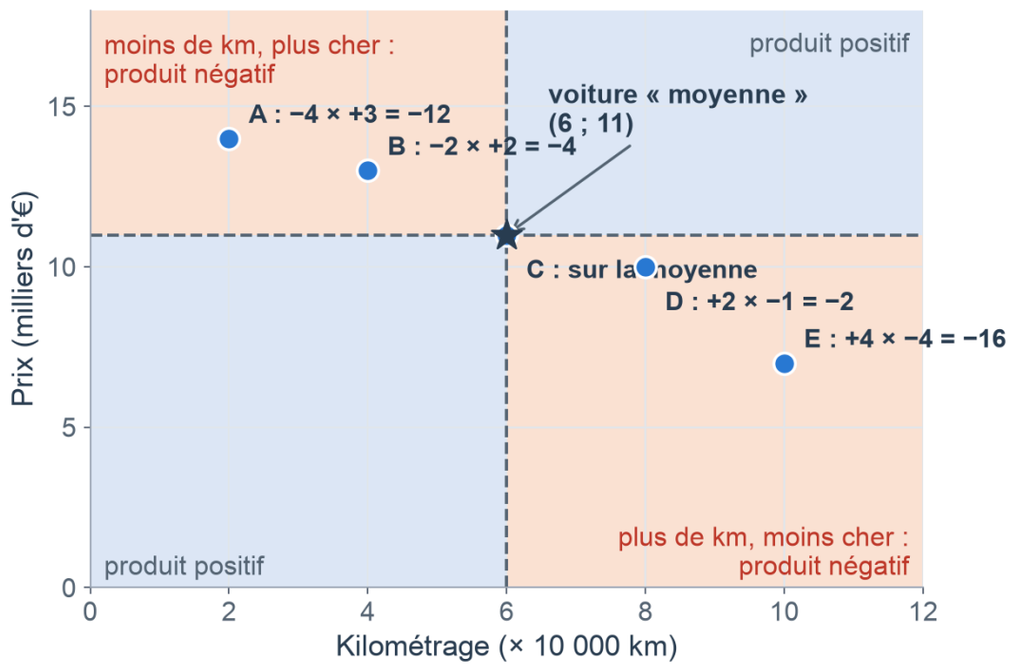
Ce qui sort

$\bar{x} = 6$

$\bar{y} = 11$

$\bar{x}$ (« x barre ») est la **moyenne des x** ; **$\bar{y}$** celle des y. On en a besoin pour mesurer chaque voiture **par rapport à la voiture « moyenne »** : 60 000 km et 11 000 €.

🧮 Le calcul (2/6) : les écarts à la moyenne



1. Pour chaque voiture : de combien s'écarte-t-elle de la moyenne ? En kilomètres : **x – 6**. En prix : **y – 11**.

2. On **multiplie** les deux écarts. Si les deux vont **dans le même sens**, le produit est positif ; **en sens contraire**, négatif.

Ici, presque tous sont **négatifs** : plus de km, moins cher. Leur somme (–34) dit dans quel sens et avec quelle force x et y varient ensemble.

🧮 Le calcul (3/6) : la formule de la pente

La pente **a** répond à : **de combien le prix change-t-il quand le kilométrage augmente de 1 ?**

En haut

La **somme des produits des écarts** : à quel point x et y **bougent ensemble**.

ici : –34

÷

En bas

La **somme des carrés des écarts en x** : l'**étalement** des kilométrages.

ici : 40

=

Résultat

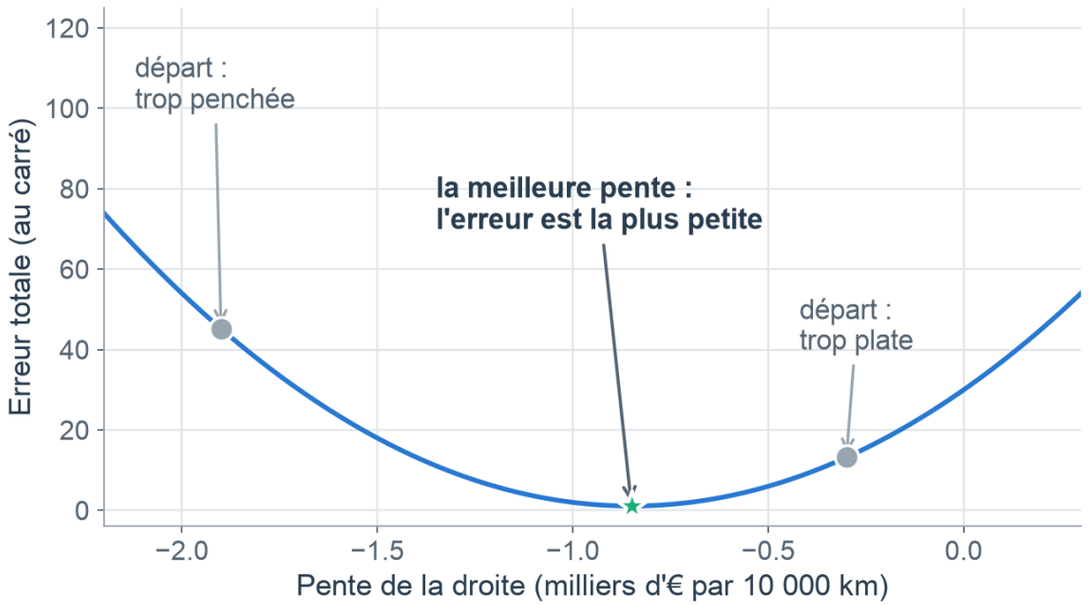
Le lien **par unité** de kilométrage : la pente.

$$a = \Sigma\,(x - \bar{x}) \times (y - \bar{y}) \,/\, \Sigma\,(x - \bar{x})^2$$

Σ (sigma) se lit « somme de » : on additionne le calcul de chaque voiture.

Pourquoi diviser ? Un écart de prix ne dit rien tant qu'on ne sait pas sur **combien de kilomètres** il s'étend : en divisant par l'étalement, on obtient la perte pour **1 unité**.

🧮 Le calcul (4/6) : d'où vient la formule ?



On cherche la pente qui donne **la somme des erreurs au carré la plus petite** : le **fond de la cuvette** (étoile).

Le fond est l'endroit où la cuvette **cesse de descendre.** Le trouver, c'est le **calcul de dérivées** (vu en mathématiques).

Ce calcul donne **exactement** la formule précédente. Nous l'**admettons** : elle tombe sur l'étoile, à **a = –0,85.**

🧮 Le calcul (5/6) : la pente a

On remplit le tableau colonne par colonne, avec $\bar{x} = 6$ et $\bar{y} = 11$, puis on applique la formule.

Voiture	x	y	x – 6	y – 11	(x – 6) × (y – 11)	(x – 6)²
A	2	14	–4	+3	–12	16
B	4	13	–2	+2	–4	4
C	6	11	0	0	0	0
D	8	10	+2	–1	–2	4
E	10	7	+4	–4	–16	16
Somme (Σ)					**–34**	**40**

a = (somme des produits) / (somme des carrés) = –34 / 40 = **–0,85**

Chaque tranche de 10 000 km en plus : **–0,85 millier d'euros, soit –850 €**.

🧮 Le calcul (6/6) : le point de départ b

Pourquoi la droite passe-t-elle par le point moyen (6 ; 11) ? Si elle passait au-dessus du nuage, presque toutes les erreurs seraient du même côté : en la descendant un peu, on ferait baisser la somme des carrés. La meilleure droite **équilibre ses erreurs** (leur somme est nulle), et cela n'arrive que si elle passe par le point moyen.

Elle passe par $(\bar{x} ; \bar{y})$, donc : $\bar{y} = a \times \bar{x} + b$. On isole b : $\mathbf{b = \bar{y} - a \times \bar{x}}$

$b = 11 - (-0{,}85) \times 6 = 11 + 5{,}1 = \mathbf{16{,}1}$

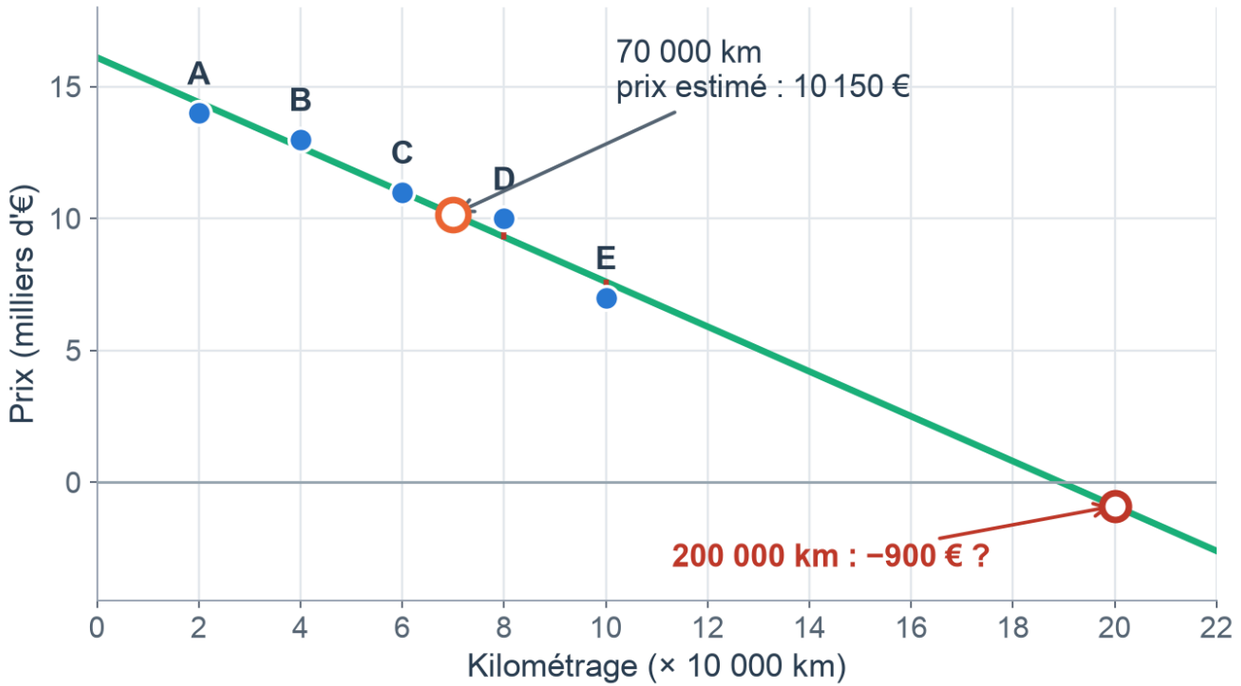
prix = –0,85 × kilométrage + 16,1

prix en milliers d'€ · kilométrage en dizaines de milliers de km

Lecture : une voiture à 0 km vaudrait 16 100 € ; chaque 10 000 km en plus la fait perdre 850 €.

🎯 Faire une prédiction

1 Les données | 2 La droite | 3 Le calcul | **4 Prédire** | 5 Évaluer



Une voiture à 70 000 km

$-0{,}85 \times 7 + 16{,}1 = \mathbf{10{,}15}$

soit environ 10 150 €

Une voiture à 200 000 km ?

$-0{,}85 \times 20 + 16{,}1 = \mathbf{-0{,}9}$: un prix négatif !

Loin des données, le modèle **ne sait plus.**

📏 Évaluer (1/2) : l'erreur moyenne

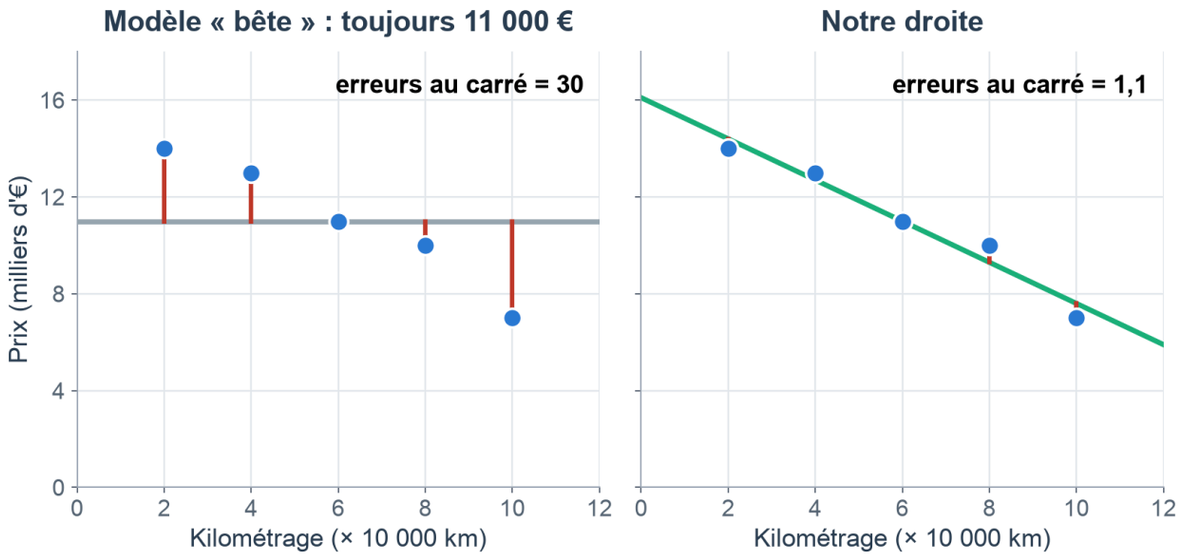
Voiture	Prix réel	Prix prédit (–0,85 x + 16,1)	Erreur (réel – prédit)
A	14	14,4	–0,4
B	13	12,7	+0,3
C	11	11,0	0
D	10	9,3	+0,7
E	7	7,6	–0,6

Erreur moyenne (sans le signe) : (0,4 + 0,3 + 0 + 0,7 + 0,6) / 5 = **0,4** milliers d'€

Le modèle se trompe de 400 € en moyenne.

RMSE : on met les erreurs **au carré** (somme 1,1), on fait la **moyenne** (1,1 / 5 = 0,22), puis la **racine carrée** pour revenir aux euros : √0,22 = **0,47**, soit 470 €. Les grosses erreurs pèsent davantage.

📏 Évaluer (2/2) : le R²



Le modèle « bête » annonce toujours le prix moyen (11 000 €). Ses erreurs au carré : $3^2 + 2^2 + 0^2 + 1^2 + 4^2 =$ **30.**

$R^2 = 1 - 1{,}1 / 30 = 0{,}96$

1,1 / 30 : la part d'erreur qui **reste.** 1 – cette part : la part d'erreur **supprimée** par la droite, soit 96 %.

$R^2 = 1$: parfait · **$R^2 = 0$** : pas mieux que la moyenne · **R^2 négatif** : pire que la moyenne

✏️ À vous de jouer

Un coureur s'entraîne. Son temps sur 5 km, semaine après semaine :

Semaine x	1	2	3	4
Temps y (minutes)	120	115	112	110

Questions : 1. Calculez a et b, **avec les mêmes étapes** que pour les 5 voitures (moyennes, écarts, produits, carrés). · 2. Quel temps après 6 semaines ? · 3. Quand passera-t-il sous 100 ?

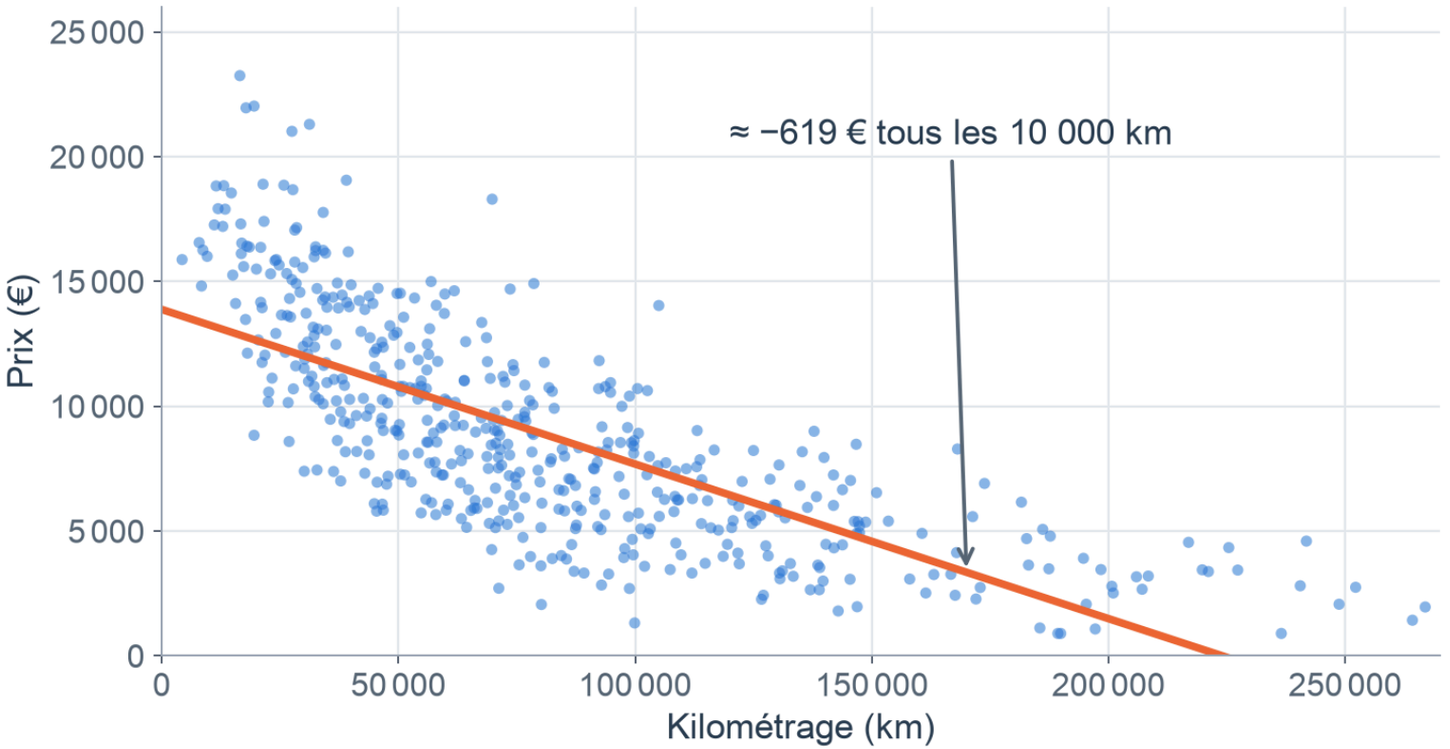
$\bar{x} = 2{,}5$ · $\bar{y} = 114{,}25$ · somme des produits = –16,5 · somme des carrés = 5

a = –3,3 · b = 122,5 : temps = 122,5 – 3,3 × semaine

Semaine 6 : 102,7 minutes · Pour 100 minutes : (122,5 – 100) / 3,3 ≈ semaine 6,8

Et dans 40 semaines ? 122,5 – 3,3 × 40 = –9,5 minutes : **un temps négatif.** On n'extrapole pas loin.

Les 500 voitures du fichier



La droite : environ **619 € de moins tous les 10 000 km**.

À l'examen (test) : **R^2 = 0,61**, erreur moyenne de l'ordre de 2 160 €.

La droite passe au milieu du nuage, mais beaucoup de voitures s'en écartent : le kilométrage ne dit pas tout.

Plusieurs caractéristiques

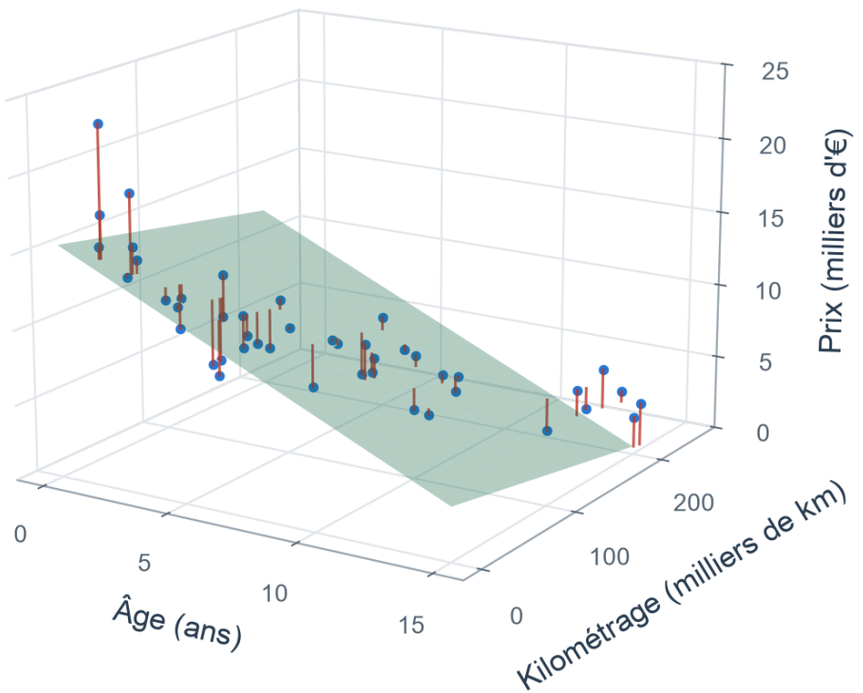
Un prix ne dépend pas que du kilométrage. On ajoute **une ligne par caractéristique**.

$$\text{prix} = a_1 \times \text{âge} + a_2 \times \text{km} + a_3 \times \text{puissance} + a_4 \times \text{état} + \ldots + b$$

Chaque nombre **a** dit l'effet d'une caractéristique, **les autres restant égales.**

Du texte comme « Diesel » ou « Bon » ? Même méthode qu'en séance 1 : **l'état en 0 à 3** (ordinal), **le carburant en colonnes 0/1** (one-hot).

🎨 Avec deux caractéristiques : un plan



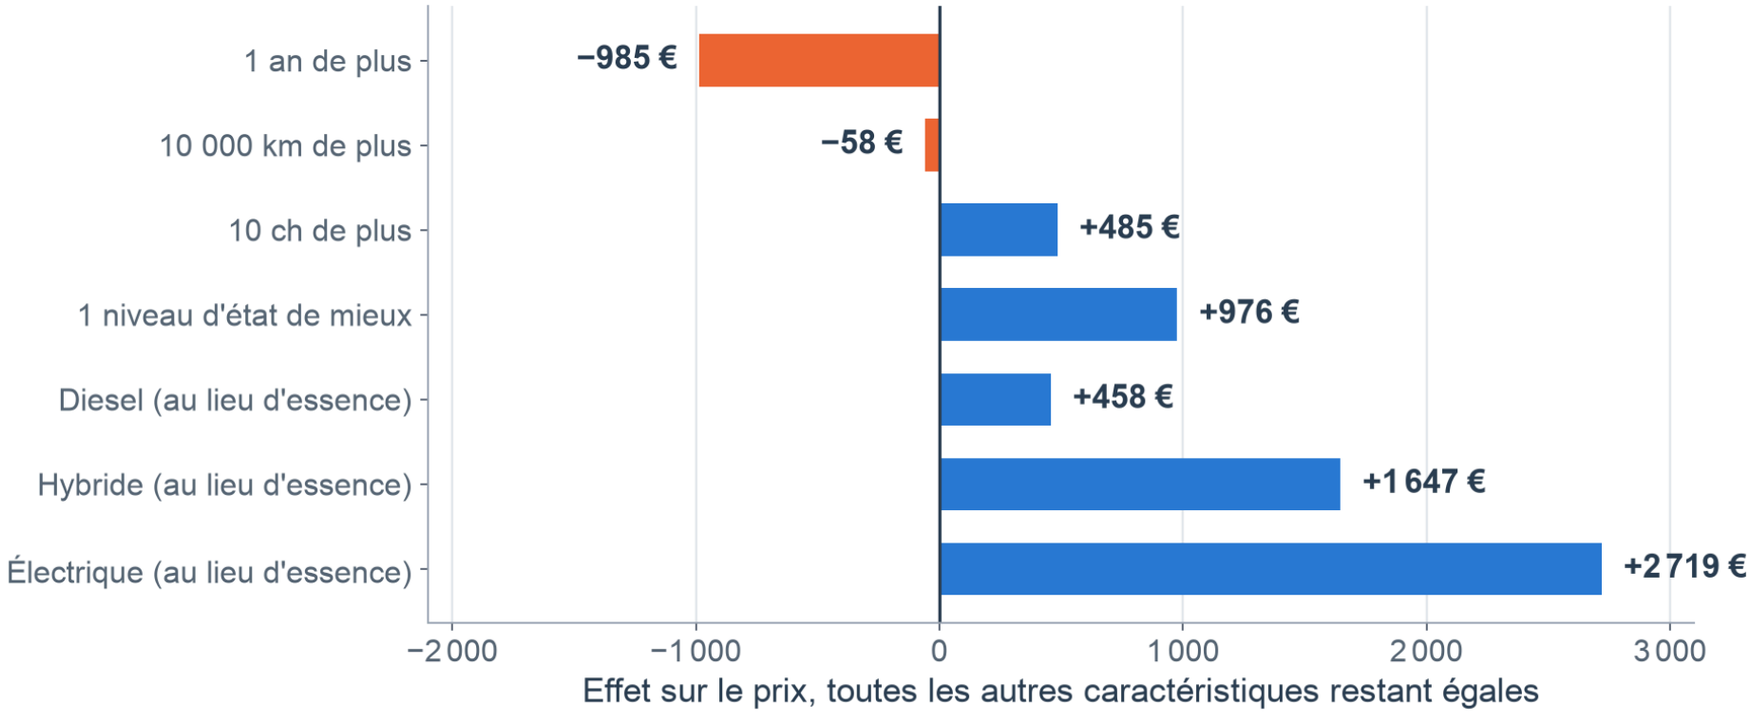
Une caractéristique : une **droite**.

Deux : un **plan**.

Plus : on ne peut plus le dessiner, mais le calcul est le même.

Points bleus : 45 voitures. Traits rouges : les erreurs.

Le résultat sur nos voitures



Une voiture **1 an plus vieille** vaut **985 € de moins**, à kilométrage, puissance, état et carburant égaux.

À l'examen : **R^2 = 0,88**, erreur moyenne **1104 €** (avec une seule caractéristique : 2 160 €).

⚠️ Les caractéristiques jumelles

Le kilométrage ne fait perdre que **58 € par 10 000 km** ici, contre 619 € tout à l'heure. Le kilométrage serait-il sans importance ?

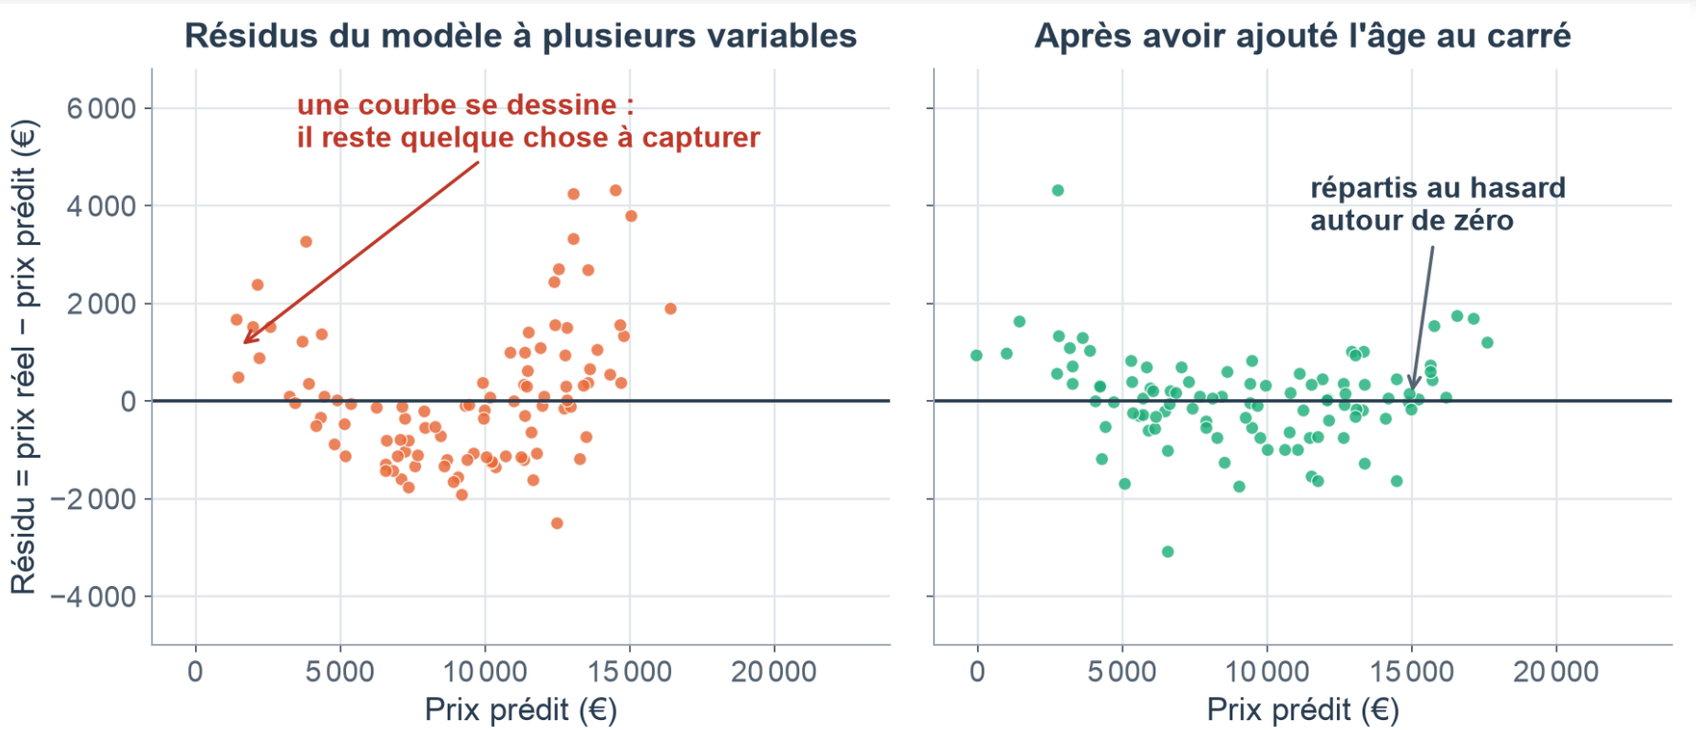
Non : l'âge et le kilométrage vont ensemble (corrélation 0,87). Une voiture âgée a beaucoup roulé.

Quand le modèle connaît déjà l'âge, le kilométrage lui apprend peu de plus.

C'est la leçon de la séance 1 sur les **colonnes jumelles** : elles racontent la même histoire. Un coefficient se lit « toutes choses égales par ailleurs », jamais tout seul.

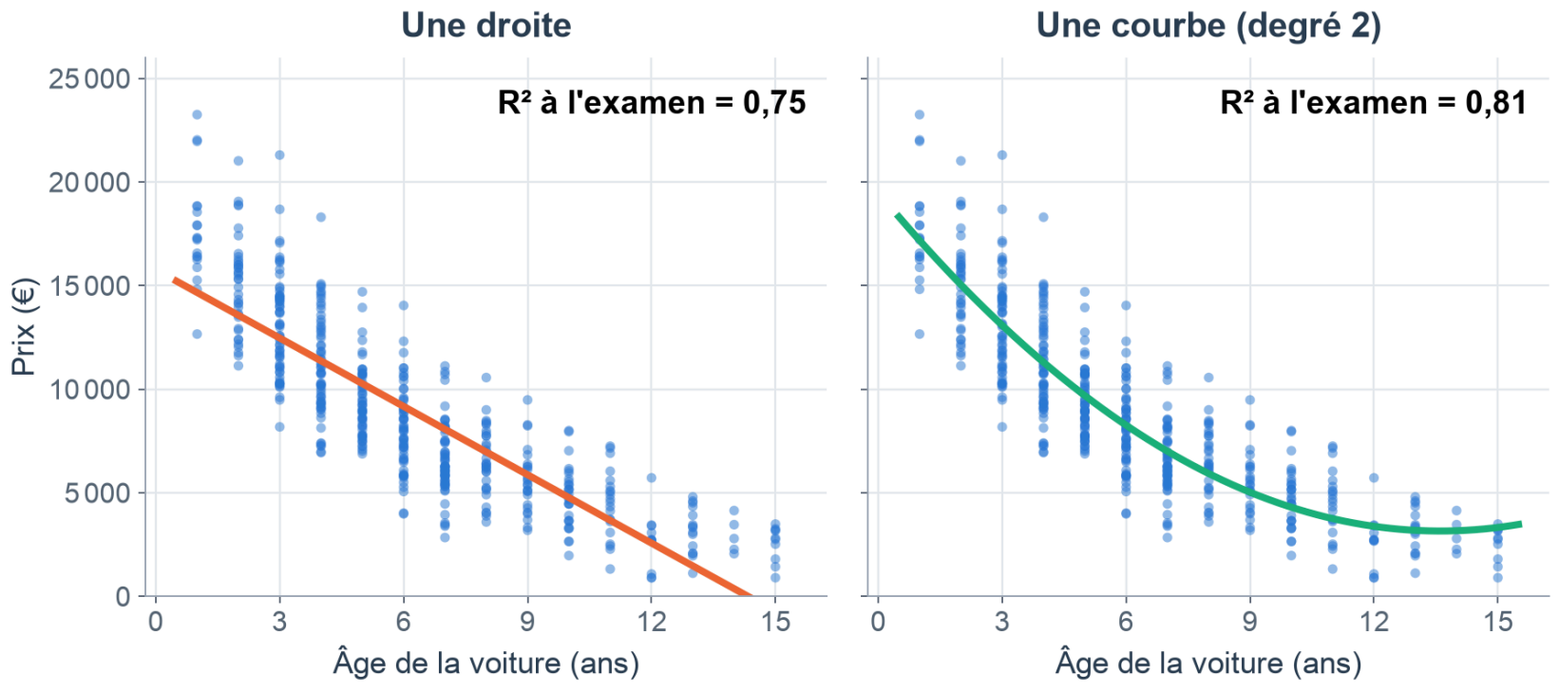
🔍 Regarder les résidus

Résidu = prix réel – prix prédit : l'erreur de chaque voiture.



Si les résidus dessinent une forme, le modèle rate quelque chose. À gauche, une courbe : il manque la courbure de l'âge. À droite, ils sont au hasard : R^2 passe de 0,88 à **0,95.**

🔄 Quand la droite ne suffit plus

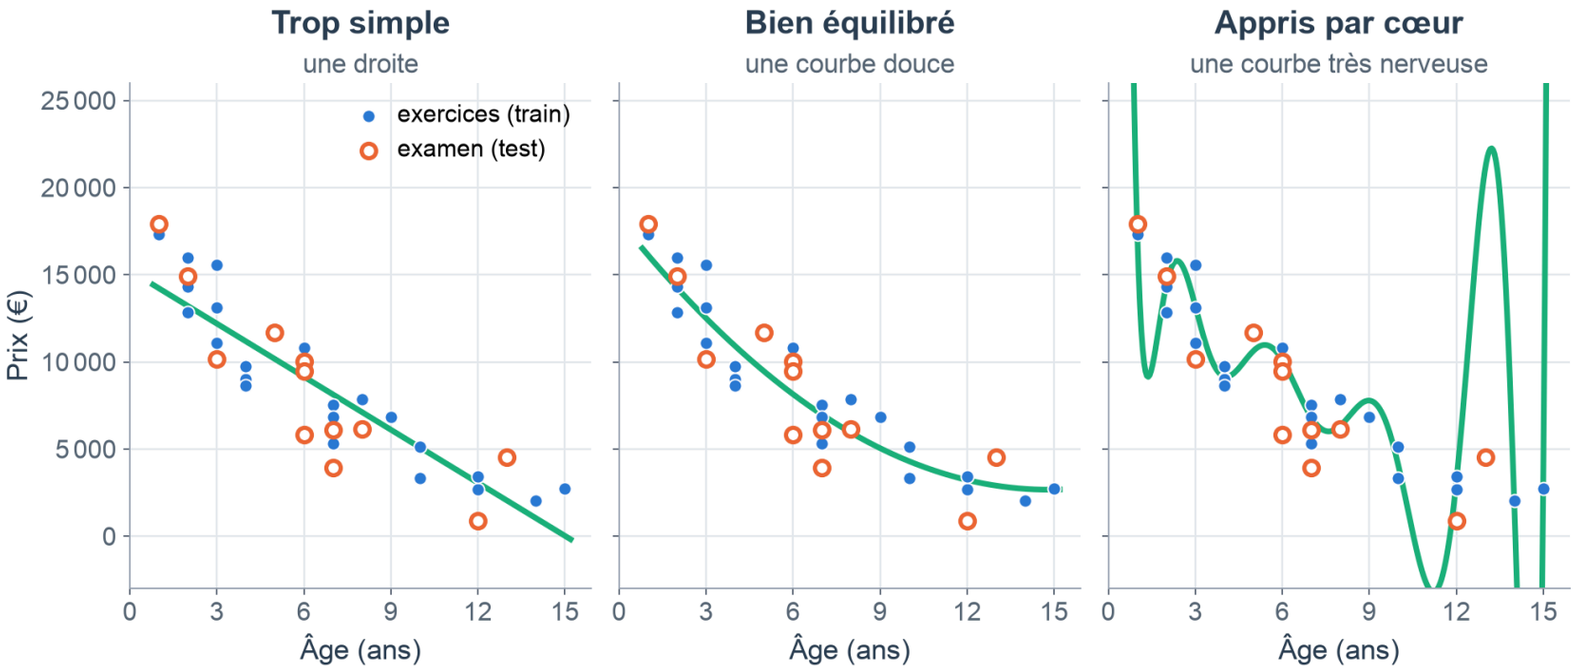


Une voiture **perd beaucoup de valeur les premières années**, puis de moins en moins : ce n'est pas une droite.

prix = a × âge² + b × âge + c

On ajoute **l'âge au carré** comme une caractéristique de plus : c'est la **régression polynomiale.**

⚖️ Combien de courbure ?



erreur sur les exercices : 1 817 €
erreur à l'examen : 2 385 €

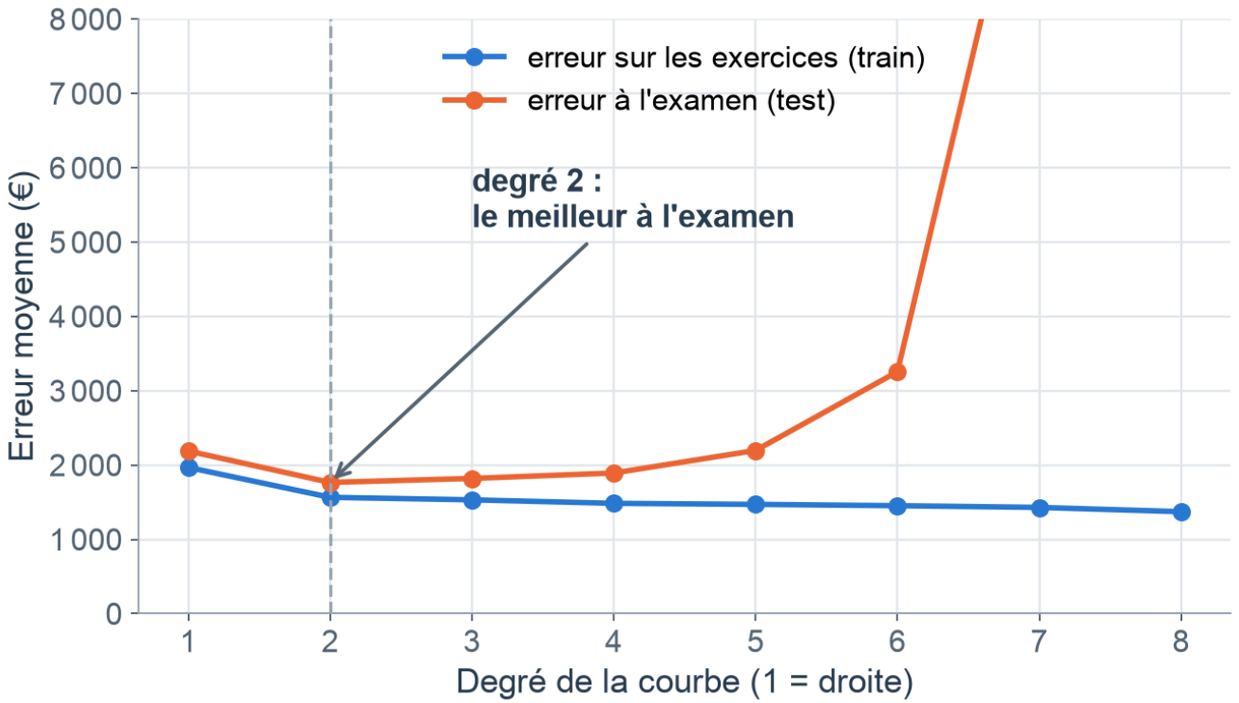
erreur sur les exercices : 1 469 €
erreur à l'examen : 1 887 €

erreur sur les exercices : 1 011 €
erreur à l'examen : 5 145 €

Même idée qu'en séance 2 : une courbe **trop simple** rate le fond, une courbe **trop nerveuse** apprend les exercices par cœur.

À droite, l'erreur sur les exercices est la plus basse et l'erreur à l'examen **remonte** : c'est le **sur-apprentissage.**

Choisir le degré



Sur les exercices, l'erreur ne fait que **baisser.**

À l'examen, elle baisse, puis **remonte.**

On garde le degré où l'erreur **à l'examen** est la plus petite : ici le degré 2.

Règle d'or : commencer simple, compliquer seulement si l'examen s'améliore.

moyenne sur 300 découpages d'un échantillon de 36 voitures

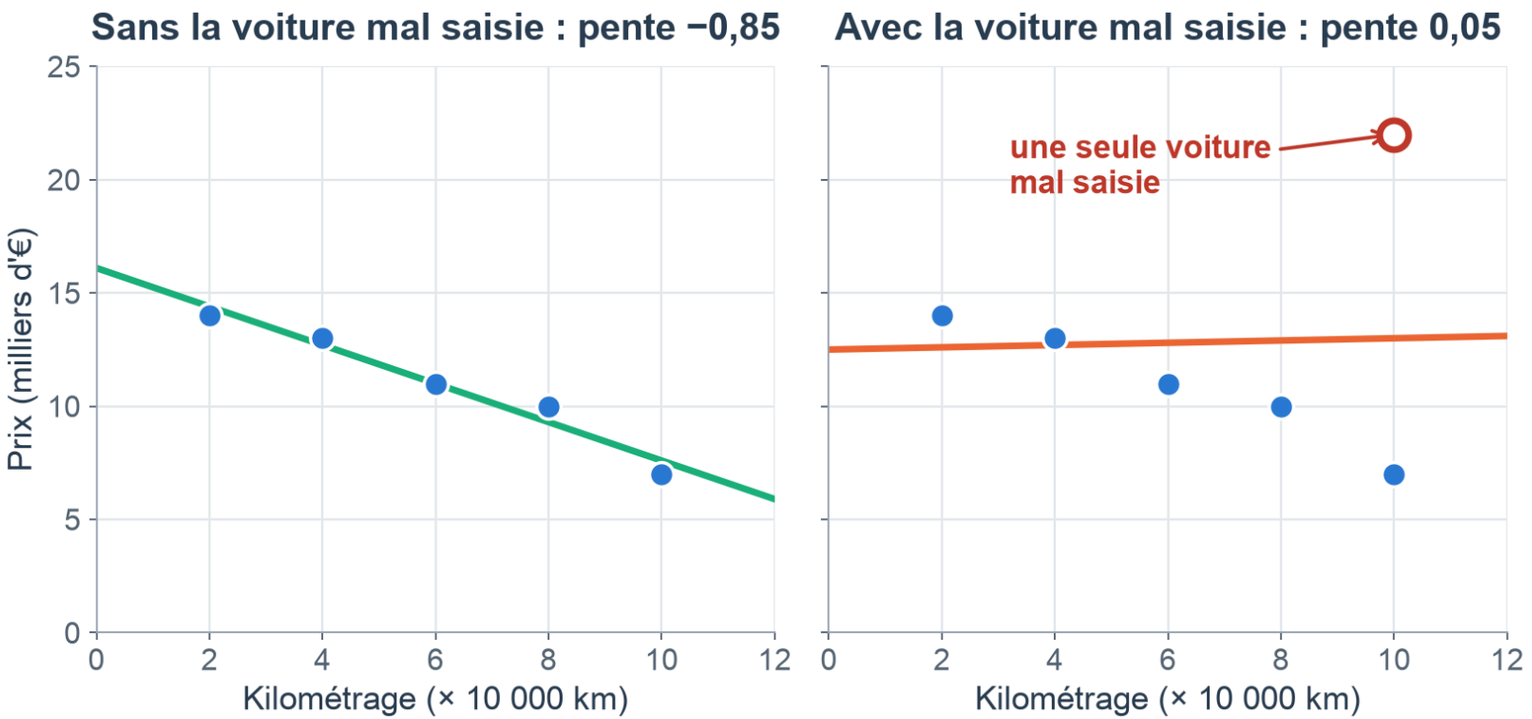
📏 Comparer les modèles

Modèle	Erreur moyenne	RMSE	R^2
« Bête » : toujours la moyenne	3 590 €	4 258 €	–0,01
Droite sur le kilométrage	2 160 €	2 640 €	0,61
Courbe sur l'âge (degré 2)	1 454 €	1 835 €	0,81
Plusieurs caractéristiques	1 104 €	1 486 €	0,88
Plusieurs caractéristiques + âge au carré	**658 €**	**929 €**	**0,95**

mesuré sur 100 voitures mises de côté (le test), jamais vues pendant l'apprentissage

Erreur moyenne : de combien on se trompe, en euros. **R^2** : la part du travail faite par rapport au modèle bête. **Toujours mesurer sur le test.**

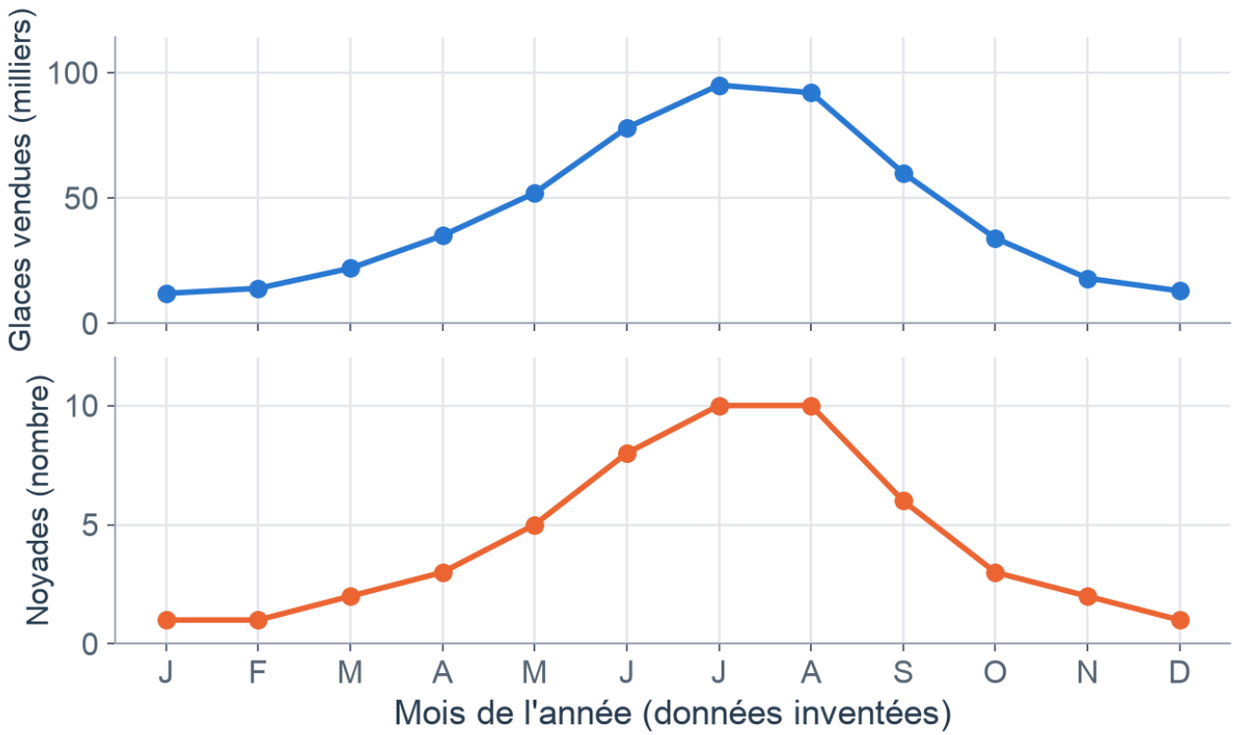
⚠️ Les pièges (1/2) : une erreur de saisie



Une seule voiture mal saisie, et la pente passe de **–0,85** à **0,05** : la droite ne descend plus du tout.

La droite est **sensible aux valeurs aberrantes.** Retour à la séance 1 : z-score ou quartiles **avant** de modéliser.

⚠️ Les pièges (2/2) : corrélation et causalité



Les ventes de glaces et les noyades montent et descendent ensemble (corrélation 0,997).

Les glaces ne font noyer personne. Les deux dépendent de l'été.

Un modèle **prédit** ; il ne dit pas **pourquoi**. Un coefficient n'est pas une cause.

🤔 Quel modèle choisir ?

1. Commencer simple

Une droite sur la caractéristique la plus parlante.

2. Ajouter des caractéristiques

Si l'erreur à l'examen baisse.

3. Courber

Si les résidus dessinent une forme.

Principe d'Occam : entre deux modèles aussi bons à l'examen, on garde **le plus simple.**

À chaque étape : **découper en train et test, apprendre sur le train, mesurer sur le test.** La préparation (séance 1) aussi se règle sur le train seulement.

💻 En Python : la droite

```python
# Les données (le fichier de Nathalie)
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split

voitures = pd.read_csv("donnees/voitures-comtoise-auto.csv")
X = voitures[["kilometrage"]]      # la caractéristique (deux crochets)
y = voitures["prix"]               # la cible

# Apprendre sur le train, mesurer sur le test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

modele = LinearRegression()
modele.fit(X_train, y_train)             # on cherche a et b

print(modele.coef_[0])                   # a : l'effet d'un kilomètre
print(modele.intercept_)                 # b : le prix à 0 km
print(modele.score(X_test, y_test))      # le R² sur le test
```

fit cherche la droite, **predict** fait une prédiction, **score** donne le R^2.

💻 En Python : plusieurs caractéristiques

```
from sklearn.metrics import mean_absolute_error

voitures["age"] = 2026 - voitures["annee"]
voitures["etat_num"] = voitures["etat"].map(
    {"Mauvais": 0, "Correct": 1, "Bon": 2, "Très bon": 3})    # ordinal

colonnes = ["age", "kilometrage", "puissance_ch", "etat_num", "carburant"]
X = pd.get_dummies(voitures[colonnes], columns=["carburant"])  # one-hot

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

modele = LinearRegression().fit(X_train, y_train)
prix_predits = modele.predict(X_test)

print(mean_absolute_error(y_test, prix_predits))    # l'erreur moyenne, en €
print(dict(zip(X.columns, modele.coef_)))           # l'effet de chaque colonne
```

💻 En Python : une courbe

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import PolynomialFeatures, StandardScaler

X = voitures[["age"]]
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)

for degre in [1, 2, 3, 6]:
    modele = make_pipeline(StandardScaler(),
                           PolynomialFeatures(degre),
                           LinearRegression())
    modele.fit(X_train, y_train)
    print(degre, modele.score(X_train, y_train), modele.score(X_test, y_test))
```

make_pipeline enchaîne les étapes : standardiser, ajouter les puissances de l'âge, ajuster. On compare le score sur le train et sur le test.

🔑 À retenir

1. **Régression** : prédire un nombre à partir de caractéristiques.
2. Une droite **prix = a × x + b** ; la meilleure rend la somme des erreurs au carré la plus petite.
3. **Plusieurs caractéristiques** : un coefficient par colonne, à lire « toutes choses égales ».
4. **Une courbe** quand les résidus dessinent une forme ; pas trop nerveuse.
5. Mesurer sur le **test** : erreur moyenne en euros, R^2 face au modèle bête.
6. Méfiance : **extrapolation**, valeurs aberrantes, corrélation ≠ causalité.

🎯 Quiz rapide

1. Prédire le temps de trajet d'un livreur : régression ou classification ?

Régression : la réponse est un nombre de minutes.

2. Mon modèle a un R^2 de 0,99 sur le train et 0,60 sur le test. Je suis content ?

Non : c'est du sur-apprentissage. Ce qui compte, c'est le test.

3. Le prix d'un logement selon sa surface, son quartier et son étage : quel outil ?

La régression multiple (le quartier en colonnes 0/1).

4. Le modèle annonce –900 € pour une voiture à 200 000 km. Que faire ?

Ne pas extrapoler hors des données : un prix ne peut pas être négatif.

🎓 Conclusion

« Tous les modèles sont faux, mais certains sont utiles. »

George Box

Vous savez maintenant :

- reconnaître un problème de régression ;
- calculer une droite à la main, et la lire ;
- passer à plusieurs caractéristiques, ou à une courbe ;
- mesurer la qualité d'un modèle sur le test ;
- éviter les pièges classiques.